

Home Credit Open Solution 的受控复现

性能增益来自特征表示、动态行为，还是模型集成？

工业数据分析课程项目

2026 年 6 月 20 日

第一章 问题背景与研究问题

1.1 任务背景

Home Credit Default Risk 任务要回答的问题是：一名贷款申请人是否会出现还款困难。每名申请人由 `SK_ID_CURR` 唯一标识，二元标签 `TARGET` 在出现还款困难时取 1。官方评价指标是 ROC 曲线下面积（AUC），它衡量的是模型是否给高风险申请人赋予了更高的预测概率——也就是模型对“风险高低”的排序能力，而非某个固定阈值下的准确率。

这份数据并不是一张扁平的单表，而是一组关系型表格。中心的 `application` 表每名申请人占一行；其余表则分别记录征信局（bureau）历史、历史贷款申请（previous application）、分期付款（installments）、POS 与现金贷款（POS cash），以及信用卡（credit card）行为。因此，本任务的核心建模难点不只是“训练一个分类器”，更在于 **如何把变长的历史记录转化为申请人级别的特征**。这一步“表示构造”决定了模型最终能够“看到”哪些信息。

1.2 Open Solution 的演化路径

开源的 Home Credit 解答先后经历了六个有名称的版本。这些版本对理解建模逻辑很有价值，但它们**不能被直接当作受控实验来比较**：因为在相邻两个版本之间，特征工程、清洗规则、模型类别与超参数往往同时发生了变化，分数的提升无法干净地归因到某一处改动。

表 1.1: 作为项目参照的历史 Open Solution 版本。

版本	主要变化	在本项目中的角色
Chestnut	application 单表基线	S1 基线
Seedling	application 群组聚合与更多模型	S2 群组聚合
Blossom	多张历史表的聚合特征	S3 历史信息
Tulip	群体相对特征与近期行为	S4 更精细的表示
Sunflower	清洗修复与动态特征	B2/S5 清洗与动态
Four Leaf Clover	在 OOF 预测上做 stacking	S6 模型集成

本项目的核心问题是：当开源解答的分数提升时，究竟是**哪一类新增的信息结构**带来了增益？我们并不试图逐列精确复刻原方案的全部特征，而是构建一个**受控复现**：在固定交叉验证划分与固定 LightGBM 配置的前提下，每个阶段只“打开”一个新的特征块，从而把增益归因到具体的机制上。

1.3 研究问题

报告围绕三个研究问题（Research Question, RQ）组织。

RQ1: 从 Chestnut 到 Blossom 的早期增益来自哪里？我们把候选来源拆成三类：通用的 application 群组聚合、手工构造的 application 业务比例，以及多张历史表的聚合特征。

RQ2: 从 Blossom 到 Sunflower 的后期增益来自哪里？我们考察相对同类人群的位置、近期的还款或申请行为、聚合之前是否正确清洗，以及短期相对长期的动态变化。

RQ3: 在充分的特征工程之后，stacking 为什么还能继续提升？我们利用各一级模型的折外（out-of-fold, OOF）预测，检验在不同特征块上训练出来的模型是否犯了足够不同的错误，从而让二层模型能够加以利用。

1.4 工作假设

我们的工作假设是：最大的性能增益应当来自关系型与时序型的特征表示，而不是单纯的模型选择。群组聚合可能有帮助，但预计弱于历史表特征与动态行为特征；stacking 预计只带来较小的边际增益，因为表现强的一级模型很可能共享了大量相同的风险信号。后续各章将用受控对比逐一检验这一假设。

第二章 受控复现设计

2.1 为什么需要受控复现

原始的版本历史并不是一项干净的消融实验。某个较晚版本之所以分数更高，可能源于更多特征、不同清洗、不同模型类别、不同超参数，或者 stacking 中的任意组合。为了让比较可解释，我们固定整套实验基础设施，每个阶段只改变与该阶段对应的那个特征块。

所有主线 LightGBM 阶段都使用**相同的五折分层划分、相同的模型参数与相同的输出格式**。折划分存储在 `data/folds.csv` 中；后续训练命令只读取该文件，绝不重新进行随机切分。这保证了 AUC 的变化主要反映新增特征的作用，而不是划分或调参的噪声。

2.2 评价协议

主指标是**折外 AUC (OOF AUC)**。对每一折，模型在其余四折上训练，并对留出的这一折做预测。把五折的验证预测拼接起来，就得到了每名训练申请人各一条预测：

$$\text{OOF} = \{(\text{SK_ID_CURR}_i, y_i, \hat{p}_i, \text{fold_id}_i)\}_{i=1}^n.$$

随后在整个训练集上计算 OOF AUC。相比训练集 AUC，这一指标更可靠，因为每条预测都来自一个**没有见过该申请人的模型**。我们同时汇报五个折 AUC 的均值与标准差，用以衡量增益的稳定性。

我们对每个配对对比 $A \rightarrow B$ 还记录 OOF AUC 的差值 $\Delta_{A \rightarrow B} = \text{AUC}_{\text{OOF}}(B) - \text{AUC}_{\text{OOF}}(A)$ 以及五折上的逐折配对差值。我们不做复杂的显著性检验，而采用一个预先规定的描述性判据：

平均增益为正，且至少 4 个折方向一致，称为“稳定增益”；否则称为“不稳定或证据不足”。

2.3 实验矩阵

本章只详细说明已经完成的 S1、S2 及其 Logistic 桥接；B1、S3 将在第三章随 RQ1 一并展开，S4-S6 属于后续 RQ2、RQ3 的内容。

表 2.1: 受控特征阶段。

阶段	特征内容	目的
S1	application 数值与类别特征	基线
S2	S1 + application 群组聚合原值	通用群组聚合
B1	S1 + 业务比例与 EXT_SOURCE 汇总	application 业务特征
S3	B1 + 五张历史表的基础聚合	历史信息
S4	S3 + 群体相对位置与近期窗口	更精细的表示
B2	S4, 但在聚合之前清洗	清洗顺序的影响
S5	B2 + 短期/长期比值与趋势特征	动态行为
S6	在一级 OOF 预测上做 stacking	预测互补性

2.4 S1 基线

S1 只使用 application 表。数值列与类别列遵循原项目的 NUMERICAL_COLUMNS 与 CATEGORICAL_COLUMNS。标识符 SK_ID_CURR 与标签 TARGET 不作为模型特征。若干已知的异常编码被转为缺失值，包括 DAYS_EMPLOYED=365243、CODE_GENDER=XNA、NAME_FAMILY_STATUS=Unknown、ORGANIZATION_TYPE=XNA 以及 DAYS_LAST_PHONE_CHANGE=0。

S1 刻意排除了比例特征、群组聚合、历史表特征与动态窗口。它提供了衡量后续特征块作用的参照点。

2.5 S2 application 群组聚合

S2 在 S1 之上加入 fold-safe 的 application 群组聚合原值。当前受控版本的 S2 使用仓库中的 FULL_GROUPBY_SPECS: 301 个群组聚合特征，加上 S1 的 78 个基础特征，共计 379 个特征。

聚合原值在若干核心 application 变量上计算，包括贷款金额、年金、收入、商品价格、外部评分、与年龄相关的天数计数、家庭人数与车龄等；聚合函数为 min、mean、max、sum、var、median。主要的分组键包括“学历 × 性别”“家庭状况 × 学历”“家庭状况 × 性别”，以及若干更具体的职业与地区组合。

S2 只保留群组聚合原值，不构造形如 $x - \bar{x}_{g(i)}$ 的差值特征或绝对差值特征。这些差值特征被保留到后续 S4 的群体相对位置实验中。

2.6 fold-safe 群组聚合规则

每个群组聚合都只在当前训练折内拟合。对验证折或测试集的申请人，已拟合的群组聚合表只作为一张查找表使用。若验证折或测试集中出现的某个 group 在训练折内未曾出现，则该特征用训练折上该聚合的全局均值填补。构造群组聚合时绝不使用标签。

这条规则避免了泄漏：验证行永远不会参与生成用于预测它自身的统计量。任何与折相关的统计（群组均值、编码器、标准化等）都遵循同样的“先在训练折 fit、再分别 transform”模式。

2.7 S2 Logistic 桥接

为了检验 Seedling 式的特征空间是否特别依赖非线性树模型，我们在同一套 379 维 S2 特征上额外训练了一个带 L_2 正则的 Logistic 回归。数值变量在训练折内做中位数填补与标准化；类别变量做 one-hot 编码，转换时忽略未见类别。该模型不是 S2 的主结果，而是一个桥接实验，同时也是后续 stacking 阶段可能的输入。

2.8 当前 Member A 结果

表 2.2 汇总了当前 Member A 的产出。S2 是 379 维的受控群组聚合版本；S2-full 则是一个单独的诊断性运行，它额外包含了群组差值特征，因此不是唯一的官方 S2 阶段。

表 2.2: 当前 Member A 受控复现结果。

阶段	模型	特征数	OOF AUC	折 AUC 标准差
S1	LightGBM	78	0.757646	0.002460
S2	LightGBM	379	0.757405	0.002358
S2-full	LightGBM	801	0.760329	0.002746
S2-Logistic	Logistic	379	0.743054	0.003636

受控的 S2 阶段在 OOF AUC 上并未超过 S1。这说明，仅仅加入 application 群组聚合原值，不足以复现原始 Seedling 历史中所观察到的较强增益。与之相对，S2-full 提升了 OOF AUC，表明更大的原始风格特征块——特别是其中的群组相对差值特征——携带了额外信号。这一区分对后文很重要：S2 应被理解为“通用群组聚合”的受控检验，而 S2-full 则是“移除相对位置部分会损失什么”的证据。

2.9 可复现产物

每个阶段都写出相同的四个核心产物：

```
results/<stage>/oof.parquet
results/<stage>/fold_metrics.csv
results/<stage>/feature_names.txt
results/<stage>/config.yaml
```

OOF 文件包含 SK_ID_CURR、TARGET、fold_id 与 prediction。实现会校验：每名训练申请人恰好出现一次、预测为 $[0, 1]$ 内的有限概率、且折标识与 data/folds.csv 完全一致。

第三章 RQ1：从基础特征到关系型表示

3.1 本章目标

RQ1 关心的是 Open Solution 早期 (Chestnut → Blossom) 那一大段增益究竟来自何处。借助受控复现，我们把这段历史拆成四组可比的对比，每一组只隔离一个机制：

- **S2 – S1**: 通用 application 群组聚合原值的价值；
- **B1 – S1**: 业务比例与 EXT_SOURCE 汇总的价值；
- **S3 – B1**: 五张历史表基础聚合的价值；
- **S2-LGBM – S2-Logistic**: 同一特征空间下，树模型非线性带来的额外价值。

其中 B1 是一个**桥接实验**：它仍只使用 application 单表，但加入了 Blossom 中最核心的少量手工特征——三个业务比例

$$\frac{\text{AMT_ANNUITY}}{\text{AMT_INCOME_TOTAL}}, \quad \frac{\text{AMT_CREDIT}}{\text{AMT_INCOME_TOTAL}}, \quad \frac{\text{AMT_CREDIT}}{\text{AMT_ANNUITY}},$$

以及 EXT_SOURCE_1/2/3 的 mean、min、max、std 共四个汇总。S3 则在 B1 之上再接入 bureau、previous application、installments、POS cash、credit card 五张历史表的基础聚合。B1 把“业务比例”从“多表历史”中干净地剥离出来，使我们能分别度量两者的贡献。

3.2 结果总览

表 3.1 给出 RQ1 涉及各阶段的规模与 OOF AUC，表 3.2 给出四组受控配对对比。

表 3.1: RQ1 各阶段的 OOF AUC 与规模。

阶段	模型	特征数	OOF AUC	折 AUC 标准差
S1	LightGBM	78	0.757646	0.002460
S2	LightGBM	379	0.757405	0.002358
S2-full	LightGBM	801	0.760329	0.002746
S2-Logistic	Logistic	379	0.743054	0.003636
B1	LightGBM	85	0.768159	0.001864
S3	LightGBM	126	0.785109	0.001543

表 3.2: RQ1 受控配对对比 (Δ 为 OOF AUC 差值, 同向折数为五折中差值为正的折数)。

对比	含义	Δ OOF AUC	同向折数	稳定性
S2 - S1	普通群组聚合原值	-0.000241	1/5	不稳定/证据不足
B1 - S1	业务比例 EXT_SOURCE 汇总	+0.010513	5/5	稳定增益
S3 - B1	五张历史表的基础聚合	+0.016950	5/5	稳定增益
S2-LGBM - S2-Logistic	同特征空间的树非线性	+0.014350	5/5	稳定增益

图 3.1 把前三组特征侧的对比画成一棵增益树：从 S1 出发，一条分支通向通用群组聚合 S2，另一条分支通向业务特征 B1，再由 B1 接入多表历史 S3。每条箭头标注了对应的 Δ OOF AUC 与稳定性判定。




图 3.1: RQ1 的 OOF AUC 增益树。最大的稳定增益来自多表历史聚合 (S3 - B1)，业务比例与 EXT_SOURCE 汇总 (B1 - S1) 次之，而普通群组聚合 (S2 - S1) 几乎没有贡献。

3.3 增益归因分析

3.3.1 普通群组聚合为何几乎无效

S2 相对 S1 的 OOF AUC 变化为 -0.000241 ，五折中只有 1 折方向为正，按判据属于“不稳定/证据不足”。这是一个值得认真对待的负结果，而非实现疏漏。

一个自洽的机制解释是：受控的 S2 只加入了群组聚合原值（如某个学历 $\times$ 性别群体的收入均值）。这类特征与底层个体变量高度共线，且分辨率更低——它对群体内的所有个体取同一个值。对于 LightGBM 而言，模型本就能直接在底层变量（如 AMT_INCOME_TOTAL）上做分裂，群组均值很难提供新的、可分裂的信息；在 feature_fraction=0.20 的列采样下，大量这类低信息特征甚至会稀释每棵树能采到有效特征的概率。

与之形成对照的是诊断性的 S2-full：它在群组聚合之外还加入了群组差值特征，OOF AUC 相对 S1 提升约 $+0.0027$ 。这说明信号其实并不在“群体的绝对统计量”里，而在“个人值相对

群体均值的**相对位置**” $x_i - \bar{x}_{g(i)}$ 上。这也正是项目计划把差值特征留到 S4（群体相对位置实验）的原因：把“聚合原值”与“相对位置”分开，才能避免把后者的功劳错记到前者头上。

3.3.2 业务比例与 EXT_SOURCE 的高效率

B1 相对 S1 取得 +0.010513 的稳定增益（五折全部为正），而它只新增了 7 个特征。从信息密度看，这是 RQ1 中单位特征贡献最高的特征块（见表 3.3）。

之所以如此高效，可以从两类特征各自的语义来理解。其一，EXT_SOURCE_1/2/3 是外部征信机构给出的、已经“预消化”的风险评分；它们本身就是别处模型的输出，浓缩了大量我们在 application 表里看不到的外部信息。对它们取 mean/min/max 捕捉了多个来源的“共识水平”，而 std 捕捉了来源之间的“分歧程度”——当几个外部评分互相矛盾时，往往本身就是一种风险信号。其二，三个业务比例把“能否负担得起这笔贷款”显式地表达出来：年金/收入与贷款/收入刻画偿债压力，贷款/年金近似刻画还款期限结构。这些都是树模型即便拿到原始分子分母，也未必能自行高效构造出来的比值关系。

3.3.3 多表历史聚合带来最大的绝对增益

S3 相对 B1 取得 +0.016950 的稳定增益（五折全部为正），是 RQ1 中绝对增益最大的一步，新增 41 个特征。

机制上，历史表提供的是**直接的行为证据**，与 application 的静态快照互补：bureau 的 bureau_amt_credit_sum_debt（在外负债规模）与 bureau_active_loan_ratio（活跃贷款比例）刻画现有负债负担；installments 的 installments_overdue_ratio 与平均逾期天数刻画历史还款纪律；previous application 的 previous_approved_ratio 则反映此人过往被金融机构接受的程度。这些“此人过去怎么还钱”的信息，是任何单表静态字段都无法替代的。

更重要的是，把这些变长历史记录聚合到 SK_ID_CURR 粒度，本身就是本题**最关键的表示步骤**。每名申请人在 installments 表里可能有几十上百条记录，模型无法直接消费；只有先按申请人聚合成“逾期比例”“平均少还金额”等申请人级统计量，这些行为信息才进入了模型可学习的特征空间。S3 的大幅增益，本质上是“把关系型历史转化为申请人级表示”这一动作的回报。

3.3.4 特征轴与模型轴：树非线性的作用

最后一组对比 S2-LGBM - S2-Logistic 给出 +0.014350 的稳定增益。它衡量的是：在**完全相同**的 379 维 S2 特征空间下，把线性模型换成 LightGBM 能多拿多少。这个量级与 B1、S3 的特征块增益相当，说明“模型非线性”确实是一个真实而显著的杠杆。

但需要强调，这是一个**模型轴**上的结果，与 RQ1 关心的**特征轴**问题正交，因此不应与特征块增益直接相加。一个有启发的旁证是：在更丰富的 379 维特征上，Logistic 的 OOF AUC 仅为 0.743054，仍低于在 78 维原始特征上的树模型 S1（0.757646）。换言之，“好模型 + 对线性不友好的特征”不一定胜过“树模型 + 朴素特征”。这提示我们：特征表示与模型能力是两个不同的维度，本报告的主线刻意固定模型、只改特征，正是为了把特征表示的贡献单独量化出来。

3.3.5 信息密度与跨折稳定性

把增益除以新增特征数，可以得到一个粗略但有说服力的“信息密度”视角（表 3.3）。B1 以约 1.5×10^{-3} /特征的效率领先，S3 次之，而普通群组聚合接近于零甚至为负。这支持一个朴素但重要的判断：**表示质量比特征数量更重要**——301 个低信息聚合原值，抵不过 7 个语义明确的业务特征。

表 3.3: 各特征块的信息密度（OOF AUC 增益 ÷ 新增特征数）。

特征块	新增特征数	Δ OOF AUC	每特征增益
S2 普通群组聚合	301	-0.000241	≈ 0
B1 业务比例 + EXT_SOURCE	7	+0.010513	$+1.50 \times 10^{-3}$
S3 多表历史聚合	41	+0.016950	$+4.13 \times 10^{-4}$

另一个容易被忽视的现象是**跨折方差**的下降：折 AUC 标准差从 S1 的 0.002460 降到 B1 的 0.001864，再降到 S3 的 0.001543。也就是说，有价值的特征不仅抬升了 OOF AUC 的均值，还压低了它在五折之间的波动。这与“稳定增益”判据是一致的——B1 与 S3 都是五折全部同向，增益不依赖于某一折的偶然。

3.4 与原始 Open Solution 历史的对照

把上述结果放回原始版本历史，可以看到受控复现的价值。原始 Seedling（对应 S2 的思想）在公开榜上把分数从约 0.742 提升到约 0.747，但那一版是把“群组聚合 + 群组差值 + 更多模型”一并上线的。我们的受控 S2 单独只保留群组聚合原值，结果增益约为零。这恰好暴露了直接读“版本更新日志”的风险：Seedling 的提升被笼统地归功于“groupby 特征”，而受控对比表明，真正起作用的是被一同引入的相对差值与模型扩展，而非群组聚合原值本身。这正是 B1（以及后续 B2）这类桥接实验的意义所在——把原本纠缠在一起的改动一一拆开，使“版本更新日志”变成可验证的统计学习证据。

3.5 本章结论

综合四组受控对比，RQ1 可以明确回答如下：

在受控复现下，Chestnut → Blossom 的早期增益主要来自**多表历史聚合**——S3 – B1 贡献了最大的稳定 OOF AUC 增益（+0.016950，五折全部同向）。**业务比例与 EXT_SOURCE**汇总是**高度参数高效的次要来源**（B1 – S1 为 +0.010513，单位特征贡献最高）。相比之下，普通的 **application** 群组聚合原值单独几乎没有贡献（S2 – S1 为 -0.000241，证据不足）。

这一结论细化、并基本支持了第一章的工作假设：早期增益确实以关系型特征表示为主导，而非来自模型选择；其中“把变长历史聚合为申请人级表示”是最关键的一步。同时它也修正了一个常见的直觉——“多做 groupby 聚合就会更好”在本受控设置下并不成立，群组信息真正的价值要等到 S4 以**相对位置**的形式重新引入时才会显现。