

Home Credit Open Solution 的受控复现

性能增益来自特征表示、动态行为，还是模型集成？

工业数据分析课程项目

2026 年 6 月 21 日

第一章 问题背景与研究问题

1.1 任务背景

Home Credit Default Risk 任务要回答的问题是：一名贷款申请人是否会出现还款困难。每名申请人由 `SK_ID_CURR` 唯一标识，二元标签 `TARGET` 在出现还款困难时取 1。官方评价指标是 ROC 曲线下面积（AUC），它衡量的是模型是否给高风险申请人赋予了更高的预测概率——也就是模型对“风险高低”的排序能力，而非某个固定阈值下的准确率。

这份数据并不是一张扁平的单表，而是一组关系型表格。中心的 `application` 表每名申请人占一行；其余表则分别记录征信局（bureau）历史、历史贷款申请（previous application）、分期付款（installments）、POS 与现金贷款（POS cash），以及信用卡（credit card）行为。因此，本任务的核心建模难点不只是“训练一个分类器”，更在于 **如何把变长的历史记录转化为申请人级别的特征**。这一步“表示构造”决定了模型最终能够“看到”哪些信息。

1.2 Open Solution 的演化路径

开源的 Home Credit 解答先后经历了六个有名称的版本。这些版本对理解建模逻辑很有价值，但它们**不能被直接当作受控实验来比较**：因为在相邻两个版本之间，特征工程、清洗规则、模型类别与超参数往往同时发生了变化，分数的提升无法干净地归因到某一处改动。

表 1.1: 作为项目参照的历史 Open Solution 版本。

版本	主要变化	在本项目中的角色
Chestnut	application 单表基线	S1 基线
Seedling	application 群组聚合与更多模型	S2 群组聚合
Blossom	多张历史表的聚合特征	S3 历史信息
Tulip	群体相对特征与近期行为	S4 更精细的表示
Sunflower	清洗修复与动态特征	B2/S5 清洗与动态
Four Leaf Clover	在 OOF 预测上做 stacking	S6 模型集成

本项目的核心问题是：当开源解答的分数提升时，究竟是**哪一类新增的信息结构**带来了增益？我们并不试图逐列精确复刻原方案的全部特征，而是构建一个**受控复现**：在固定交叉验证划分与固定 LightGBM 配置的前提下，每个阶段只“打开”一个新的特征块，从而把增益归因到具体的机制上。

1.3 研究问题

报告围绕三个研究问题（Research Question, RQ）组织。

RQ1: 从 Chestnut 到 Blossom 的早期增益来自哪里？我们把候选来源拆成三类：通用的 application 群组聚合、手工构造的 application 业务比例，以及多张历史表的聚合特征。

RQ2: 从 Blossom 到 Sunflower 的后期增益来自哪里？我们考察相对同类人群的位置、近期的还款或申请行为、聚合之前是否正确清洗，以及短期相对长期的动态变化。

RQ3: 在充分的特征工程之后，stacking 为什么还能继续提升？我们利用各一级模型的折外（out-of-fold, OOF）预测，检验在不同特征块上训练出来的模型是否犯了足够不同的错误，从而让二层模型能够加以利用。

1.4 工作假设

我们的工作假设是：最大的性能增益应当来自关系型与时序型的特征表示，而不是单纯的模型选择。群组聚合可能有帮助，但预计弱于历史表特征与动态行为特征；stacking 预计只带来较小的边际增益，因为表现强的一级模型很可能共享了大量相同的风险信号。后续各章将用受控对比逐一检验这一假设。

第二章 受控复现设计

2.1 为什么需要受控复现

原始的版本历史并不是一项干净的消融实验。某个较晚版本之所以分数更高，可能源于更多特征、不同清洗、不同模型类别、不同超参数，或者 stacking 中的任意组合。为了让比较可解释，我们固定整套实验基础设施，每个阶段只改变与该阶段对应的那个特征块。

所有主线 LightGBM 阶段都使用**相同的五折分层划分、相同的模型参数与相同的输出格式**。折划分存储在 `data/folds.csv` 中；后续训练命令只读取该文件，绝不重新进行随机切分。这保证了 AUC 的变化主要反映新增特征的作用，而不是划分或调参的噪声。

2.2 评价协议

主指标是**折外 AUC (OOF AUC)**。对每一折，模型在其余四折上训练，并对留出的这一折做预测。把五折的验证预测拼接起来，就得到了每名训练申请人各一条预测：

$$\text{OOF} = \{(\text{SK_ID_CURR}_i, y_i, \hat{p}_i, \text{fold_id}_i)\}_{i=1}^n.$$

随后在整个训练集上计算 OOF AUC。相比训练集 AUC，这一指标更可靠，因为每条预测都来自一个**没有见过该申请人的模型**。我们同时汇报五个折 AUC 的均值与标准差，用以衡量增益的稳定性。

我们对每个配对对比 $A \rightarrow B$ 还记录 OOF AUC 的差值 $\Delta_{A \rightarrow B} = \text{AUC}_{\text{OOF}}(B) - \text{AUC}_{\text{OOF}}(A)$ 以及五折上的逐折配对差值。我们不做复杂的显著性检验，而采用一个预先规定的描述性判据：

平均增益为正，且至少 4 个折方向一致，称为“稳定增益”；否则称为“不稳定或证据不足”。

2.3 实验矩阵

本章只详细说明已经完成的 S1、S2 及其 Logistic 桥接；B1、S3 将在第三章随 RQ1 一并展开，S4-S6 属于后续 RQ2、RQ3 的内容。

表 2.1: 受控特征阶段。

阶段	特征内容	目的
S1	application 数值与类别特征	基线
S2	S1 + application 群组聚合原值	通用群组聚合
B1	S1 + 业务比例与 EXT_SOURCE 汇总	application 业务特征
S3	B1 + 五张历史表的基础聚合	历史信息
S4	S3 + 群体相对位置与近期窗口	更精细的表示
B2	S4, 但在聚合之前清洗	清洗顺序的影响
S5	B2 + 短期/长期比值与趋势特征	动态行为
S6	在一级 OOF 预测上做 stacking	预测互补性

2.4 S1 基线

S1 只使用 application 表。数值列与类别列遵循原项目的 NUMERICAL_COLUMNS 与 CATEGORICAL_COLUMNS。标识符 SK_ID_CURR 与标签 TARGET 不作为模型特征。若干已知的异常编码被转为缺失值，包括 DAYS_EMPLOYED=365243、CODE_GENDER=XNA、NAME_FAMILY_STATUS=Unknown、ORGANIZATION_TYPE=XNA 以及 DAYS_LAST_PHONE_CHANGE=0。

S1 刻意排除了比例特征、群组聚合、历史表特征与动态窗口。它提供了衡量后续特征块作用的参照点。

2.5 S2 application 群组聚合

S2 在 S1 之上加入 fold-safe 的 application 群组聚合原值。当前受控版本的 S2 使用仓库中的 FULL_GROUPBY_SPECS: 301 个群组聚合特征，加上 S1 的 78 个基础特征，共计 379 个特征。

聚合原值在若干核心 application 变量上计算，包括贷款金额、年金、收入、商品价格、外部评分、与年龄相关的天数计数、家庭人数与车龄等；聚合函数为 min、mean、max、sum、var、median。主要的分组键包括“学历 × 性别”“家庭状况 × 学历”“家庭状况 × 性别”，以及若干更具体的职业与地区组合。

S2 只保留群组聚合原值，不构造形如 $x - \bar{x}_{g(i)}$ 的差值特征或绝对差值特征。这些差值特征被保留到后续 S4 的群体相对位置实验中。

2.6 fold-safe 群组聚合规则

每个群组聚合都只在当前训练折内拟合。对验证折或测试集的申请人，已拟合的群组聚合表只作为一张查找表使用。若验证折或测试集中出现的某个 group 在训练折内未曾出现，则该特征用训练折上该聚合的全局均值填补。构造群组聚合时绝不使用标签。

这条规则避免了泄漏：验证行永远不会参与生成用于预测它自身的统计量。任何与折相关的统计（群组均值、编码器、标准化等）都遵循同样的“先在训练折 fit、再分别 transform”模式。

2.7 S2 Logistic 桥接

为了检验 Seedling 式的特征空间是否特别依赖非线性树模型，我们在同一套 379 维 S2 特征上额外训练了一个带 L_2 正则的 Logistic 回归。数值变量在训练折内做中位数填补与标准化；类别变量做 one-hot 编码，转换时忽略未见类别。该模型不是 S2 的主结果，而是一个桥接实验，同时也是后续 stacking 阶段可能的输入。

2.8 当前 Member A 结果

表 2.2 汇总了当前 Member A 的产出。S2 是 379 维的受控群组聚合版本；S2-full 则是一个单独的诊断性运行，它额外包含了群组差值特征，因此**不是**唯一的官方 S2 阶段。表中同时列出 Kaggle 官方 public/private 榜单分数，作为 OOF 结果之外的外部检验。

表 2.2: 当前 Member A 受控复现结果与官方榜单分数。

阶段	模型	特征数	OOF AUC	Public AUC	Private AUC	折 AUC 标准差
S1	LightGBM	78	0.757646	0.74770	0.74418	0.002460
S2	LightGBM	379	0.757405	0.74656	0.74471	0.002358
S2-full	LightGBM	801	0.760329	0.74920	0.74859	0.002746
S2-Logistic	Logistic	379	0.743054	0.73544	0.73049	0.003636

受控的 S2 阶段在 OOF AUC 上并未超过 S1。这说明，仅仅加入 application 群组聚合原值，不足以复现原始 Seedling 历史中所观察到的较强增益。与之相对，S2-full 提升了 OOF AUC，表明更大的原始风格特征块——特别是其中的群组**相对差值**特征——携带了额外信号。这一区分对后文很重要：S2 应被理解为“通用群组聚合”的受控检验，而 S2-full 则是“移除相对位置部分会损失什么”的证据。

2.9 可复现产物

每个阶段都写出相同的四个核心产物：

```
results/<stage>/oof.parquet
results/<stage>/fold_metrics.csv
results/<stage>/feature_names.txt
results/<stage>/config.yaml
```

OOF 文件包含 SK_ID_CURR、TARGET、fold_id 与 prediction。实现会校验：每名训练申请人恰好出现一次、预测为 $[0, 1]$ 内的有限概率、且折标识与 data/folds.csv 完全一致。

2.10 官方榜单汇总

表 2.3 汇总了目前所有已提交阶段的 OOF AUC 与 Kaggle 官方 public/private AUC。S6 是后续 stacking 阶段，当前尚未完成；表中预留该行，方便最终报告继续接入集成结果。

表 2.3: 全阶段官方榜单汇总。S6 为后续 stacking 阶段预留。

阶段	归属	特征数	OOF AUC	Public AUC	Private AUC
S1	Member A / 基线	78	0.757646	0.74770	0.74418
S2	Member A / 群组聚合	379	0.757405	0.74656	0.74471
S2-full	诊断性群组差值	801	0.760329	0.74920	0.74859
S2-Logistic	线性模型桥接	379	0.743054	0.73544	0.73049
B1	RQ1 / 业务特征桥接	85	0.768159	0.76716	0.76307
S3	RQ1 / 历史聚合	126	0.785109	0.78900	0.78562
S4	RQ2 / 群体 + 最近	184	0.786169	0.79294	0.78666
B2	RQ2 / 清洗桥接	184	0.786196	0.79164	0.78686
S5	RQ2 / 动态特征	191	0.786342	0.79137	0.78696
S6	RQ3 / stacking (预留)	—	—	—	—

官方榜单不是本文的主要归因依据：public/private 的采样噪声和排行榜划分会让相邻阶段出现轻微换序。后续章节仍以固定五折 OOF 的配对对比解释机制，官方分数用于检查这些机制在 Kaggle 测试集上的外部一致性。

第三章 RQ1：从基础特征到关系型表示

3.1 本章目标

RQ1 关心的是 Open Solution 早期 (Chestnut $\rightarrow$ Blossom) 那一大段增益究竟来自何处。借助受控复现，我们把这段历史拆成四组可比的对比，每一组只隔离一个机制：

- **S2 – S1**: 通用 application 群组聚合原值的价值；
- **B1 – S1**: 业务比例与 EXT_SOURCE 汇总的价值；
- **S3 – B1**: 五张历史表基础聚合的价值；
- **S2-LGBM – S2-Logistic**: 同一特征空间下，树模型非线性带来的额外价值。

其中 B1 是一个桥接实验：它仍只使用 application 单表，但加入了 Blossom 中最核心的少量手工特征——三个业务比例

$$\frac{\text{AMT_ANNUITY}}{\text{AMT_INCOME_TOTAL}}, \frac{\text{AMT_CREDIT}}{\text{AMT_INCOME_TOTAL}}, \frac{\text{AMT_CREDIT}}{\text{AMT_ANNUITY}},$$

以及 EXT_SOURCE_1/2/3 的 mean、min、max、std 共四个汇总。S3 则在 B1 之上再接入 bureau、previous application、installments、POS cash、credit card 五张历史表的基础聚合。B1 把“业务比例”从“多表历史”中干净地剥离出来，使我们能分别度量两者的贡献。

3.2 结果总览

表 3.1 给出 RQ1 涉及各阶段的规模、OOF AUC 与 Kaggle 官方 public/private 分数，表 3.2 给出四组受控配对对比。

表 3.1: RQ1 各阶段的 OOF AUC、官方榜单分数与规模。

阶段	模型	特征数	OOF AUC	Public AUC	Private AUC	折 AUC 标准差
S1	LightGBM	78	0.757646	0.74770	0.74418	0.002460
S2	LightGBM	379	0.757405	0.74656	0.74471	0.002358
S2-full	LightGBM	801	0.760329	0.74920	0.74859	0.002746
S2-Logistic	Logistic	379	0.743054	0.73544	0.73049	0.003636
B1	LightGBM	85	0.768159	0.76716	0.76307	0.001864
S3	LightGBM	126	0.785109	0.78900	0.78562	0.001543

官方榜单与 RQ1 的 OOF 结论方向一致：B1 和 S3 在 public/private 上均明显高于 S1/S2 系列，说明业务比例与历史聚合带来的增益并非只存在于固定 folds 内。S2-full 在官方榜单上也高于受控 S2，进一步支持“相对位置/差值特征比群组聚合原值更有信息量”的解释。

表 3.2: RQ1 受控配对对比 (Δ 为 OOF AUC 差值，同向折数为五折中差值为正的折数)。

对比	含义	Δ OOF AUC	同向折数	稳定性
S2 - S1	普通群组聚合原值	-0.000241	1/5	不稳定/证据不足
B1 - S1	业务比例 EXT_SOURCE 汇总	+0.010513	5/5	稳定增益
S3 - B1	五张历史表的基础聚合	+0.016950	5/5	稳定增益
S2-LGBM - S2-Logistic	同特征空间的树非线性	+0.014350	5/5	稳定增益

图 3.1 把前三组特征侧的对比画成一棵增益树：从 S1 出发，一条分支通向通用群组聚合 S2，另一条分支通向业务特征 B1，再由 B1 接入多表历史 S3。每条箭头标注了对应的 Δ OOF AUC 与稳定性判定。




图 3.1: RQ1 的 OOF AUC 增益树。最大的稳定增益来自多表历史聚合 (S3 - B1)，业务比例与 EXT_SOURCE 汇总 (B1 - S1) 次之，而普通群组聚合 (S2 - S1) 几乎没有贡献。

3.3 增益归因分析

3.3.1 普通群组聚合为何几乎无效

S2 相对 S1 的 OOF AUC 变化为 -0.000241，五折中只有 1 折方向为正，按判据属于“不稳定/证据不足”。这是一个值得认真对待的负结果，而非实现疏漏。

一个自洽的机制解释是：受控的 S2 只加入了群组聚合原值（如某个学历 × 性别群体的收入均值）。这类特征与底层个体变量高度共线，且分辨率更低——它对群体内的所有个体取同一个值。对于 LightGBM 而言，模型本就能直接在底层变量（如 AMT_INCOME_TOTAL）上做分裂，

群组均值很难提供新的、可分裂的信息；在 `feature_fraction=0.20` 的列采样下，大量这类低信息特征甚至会稀释每棵树能采到有效特征的概率。

与之形成对照的是诊断性的 S2-full：它在群组聚合之外还加入了群组差值特征，OOF AUC 相对 S1 提升约 +0.0027。这说明信号其实并不在“群体的绝对统计量”里，而在“个人值相对群体均值的相对位置” $x_i - \bar{x}_{g(i)}$ 上。这也正是项目计划把差值特征留到 S4（群体相对位置实验）的原因：把“聚合原值”与“相对位置”分开，才能避免把后者的功劳错记到前者头上。

3.3.2 业务比例与 EXT_SOURCE 的高效率

B1 相对 S1 取得 +0.010513 的稳定增益（五折全部为正），而它只新增了 7 个特征。从信息密度看，这是 RQ1 中单位特征贡献最高的特征块（见表 3.3）。

之所以如此高效，可以从两类特征各自的语义来理解。其一，EXT_SOURCE_1/2/3 是外部征信机构给出的、已经“预消化”的风险评分；它们本身就是别处模型的输出，浓缩了大量我们在 application 表里看不到的外部信息。对它们取 mean/min/max 捕捉了多个来源的“共识水平”，而 std 捕捉了来源之间的“分歧程度”——当几个外部评分互相矛盾时，往往本身就是一种风险信号。其二，三个业务比例把“能否负担得起这笔贷款”显式地表达出来：年金/收入与贷款/收入刻画偿债压力，贷款/年金近似刻画还款期限结构。这些都是树模型即便拿到原始分子分母，也未必能自行高效构造出来的比值关系。

3.3.3 多表历史聚合带来最大的绝对增益

S3 相对 B1 取得 +0.016950 的稳定增益（五折全部为正），是 RQ1 中绝对增益最大的一步，新增 41 个特征。

机制上，历史表提供的是直接的行为证据，与 application 的静态快照互补：bureau 的 bureau_amt_credit_sum_debt（在外负债规模）与 bureau_active_loan_ratio（活跃贷款比例）刻画现有负债负担；installments 的 installments_overdue_ratio 与平均逾期天数刻画历史还款纪律；previous application 的 previous_approved_ratio 则反映此人过往被金融机构接受的程度。这些“此人过去怎么还钱”的信息，是任何单表静态字段都无法替代的。

更重要的是，把这些变长历史记录聚合到 SK_ID_CURR 粒度，本身就是本题最关键的表示步骤。每名申请人在 installments 表里可能有几十上百条记录，模型无法直接消费；只有先按申请人聚合成“逾期比例”“平均少还金额”等申请人级统计量，这些行为信息才进入了模型可学习的特征空间。S3 的大幅增益，本质上是“把关系型历史转化为申请人级表示”这一动作的回报。

3.3.4 特征轴与模型轴：树非线性的作用

最后一组对比 S2-LGBM - S2-Logistic 给出 +0.014350 的稳定增益。它衡量的是：在完全相同的 379 维 S2 特征空间下，把线性模型换成 LightGBM 能多拿多少。这个量级与 B1、S3 的特征块增益相当，说明“模型非线性”确实是一个真实而显著的杠杆。

但需要强调，这是一个模型轴上的结果，与 RQ1 关心的特征轴问题正交，因此不应与特征块增益直接相加。一个有启发的旁证是：在更丰富的 379 维特征上，Logistic 的 OOF AUC 仅为 0.743054，仍低于在 78 维原始特征上的树模型 S1（0.757646）。换言之，“好模型 + 对线性

不友好的特征”不一定胜过“树模型 + 朴素特征”。这提示我们：特征表示与模型能力是两个不同的维度，本报告的主线刻意固定模型、只改特征，正是为了把特征表示的贡献单独量化出来。

3.3.5 信息密度与跨折稳定性

把增益除以新增特征数，可以得到一个粗略但有说服力的“信息密度”视角（表 3.3）。B1 以约 1.5×10^{-3} /特征的效率领先，S3 次之，而普通群组聚合接近于零甚至为负。这支持一个朴素但重要的判断：**表示质量比特征数量更重要**——301 个低信息聚合原值，抵不过 7 个语义明确的业务特征。

表 3.3: 各特征块的信息密度 (OOF AUC 增益 ÷ 新增特征数)。			
特征块	新增特征数	ΔOOF AUC	每特征增益
S2 普通群组聚合	301	-0.000241	≈ 0
B1 业务比例 + EXT_SOURCE	7	+0.010513	$+1.50 \times 10^{-3}$
S3 多表历史聚合	41	+0.016950	$+4.13 \times 10^{-4}$

另一个容易被忽视的现象是跨折方差的下降：折 AUC 标准差从 S1 的 0.002460 降到 B1 的 0.001864，再降到 S3 的 0.001543。也就是说，有价值的特征不仅抬升了 OOF AUC 的均值，还压低了它在五折之间的波动。这与“稳定增益”判据是一致的——B1 与 S3 都是五折全部同向，增益不依赖于某一折的偶然。

3.4 与原始 Open Solution 历史的对照

把上述结果放回原始版本历史，可以看到受控复现的价值。原始 Seedling（对应 S2 的思想）在公开榜上把分数从约 0.742 提升到约 0.747，但那一版是把“群组聚合 + 群组差值 + 更多模型”一并上线的。我们的受控 S2 单独只保留群组聚合原值，结果增益约为零。这恰好暴露了直接读“版本更新日志”的风险：Seedling 的提升被笼统地归功于“groupby 特征”，而受控对比表明，真正起作用的是被一同引入的相对差值与模型扩展，而非群组聚合原值本身。这正是 B1（以及后续 B2）这类桥接实验的意义所在——把原本纠缠在一起的改动一一拆开，使“版本更新日志”变成可验证的统计学习证据。

3.5 本章结论

综合四组受控对比，RQ1 可以明确回答如下：

在受控复现下，Chestnut → Blossom 的早期增益主要来自多表历史聚合——S3 – B1 贡献了最大的稳定 OOF AUC 增益（+0.016950，五折全部同向）。业务比例与 EXT_SOURCE 汇总是高度参数高效的次要来源（B1 – S1 为 +0.010513，单位特征贡献最高）。相比之下，普通的 application 群组聚合原值单独几乎没有贡献（S2 – S1 为 -0.000241，证据不足）。

这一结论细化、并基本支持了第一章的工作假设：早期增益确实以关系型特征表示为主导，而非来自模型选择；其中“把变长历史聚合为申请人级表示”是最关键的一步。同时它也修正了一个常见的直觉——“多做 groupby 聚合会更好”在本受控设置下并不成立，群组信息真正的价值要等到 S4 以**相对位置**的形式重新引入时才会显现。

第四章 RQ2：后期增益来自更精细的信息组织，还是边际改进？

4.1 本章目标

RQ2 关心的是 Blossom (solution-3) 之后，从 Tulip (solution-4) 到 Sunflower (solution-5) 那段持续提升背后，究竟是哪一类更精细的信息组织在起作用。RQ1 已经证明：Chestnut $\rightarrow$ Blossom 的早期增益中，多表历史聚合贡献了约 +0.017，业务比例贡献了约 +0.011，而普通群组聚合单独几乎无效。RQ2 继续追问：在此基础上，是什么让分数继续走高？

原方案 Tulip 和 Sunflower 的升级是复合型的——版本之间同时打开了群体相对位置、最近行为窗口、清洗修正、和动态比值/趋势等多种改动。受控复现将这一复合体拆为三个独立对比：

- **S4 – S3**：群体相对位置与最近窗口行为的价值；
- **B2 – S4**：聚合前对异常编码进行清洗的价值；
- **S5 – B2**：短期/长期比值与趋势特征的价值。

其中，**B2 是 RQ2 中最重要的桥接实验**：它和 S4 使用完全相同的特征列（184 列，名称一致），唯一的区别是 B2 的历史表聚合在清洗后的原表上计算，而 S4 在未经清洗的原表上聚合。因此 B2 – S4 能够干净地剥离出 Sunflower 文档中“清洗修复”的独立贡献——这是原方案六个版本都未提供的因果型证据。

4.2 结果总览

表 4.1 给出 RQ2 涉及各阶段的规模与 OOF AUC，表 4.2 补充官方 Kaggle public/private 榜单分数，表 4.3 给出三组受控配对对比。

官方榜单整体支持 RQ2 的方向：S4–S5 均高于 S3，说明后期特征组织确实能带来额外信号。但 public/private 与 OOF 并不完全同序，例如 S4 的 public 分数最高，而 S5 的 private 分数最高。因此，下文的增益归因仍以固定 folds 下的 OOF 配对对比为主，官方榜单仅作为外部一致性检查。

图 4.1 把三组对比画成增益树：从 S3 出发，首先加入群体相对位置和最近窗口（S4），然后考察清洗效果（B2），最后叠加动态比值和趋势（S5）。每条箭头标注 Δ OOF AUC 与稳定性判定。

表 4.1: RQ2 各阶段的 OOF AUC 与规模。S3 作为上游基线一并列出。

阶段	特征数	OOF AUC	折 AUC 标准差
S3 (Blossom)	126	0.785109	0.001543
S4 (Tulip, 群体 + 最近)	184	0.786169	0.001464
B2 (清洗修复, 桥接)	184	0.786196	0.001543
S5 (Sunflower, 动态特征)	191	0.786342	0.001491

表 4.2: RQ2 阶段的 Kaggle 官方榜单对照。官方分数来自 `results/summary.csv` 中已完成提交的 public/private AUC。

阶段	OOF AUC	Public AUC	Private AUC
S3 (Blossom)	0.785109	0.78900	0.78562
S4 (Tulip, 群体 + 最近)	0.786169	0.79294	0.78666
B2 (清洗修复, 桥接)	0.786196	0.79164	0.78686
S5 (Sunflower, 动态特征)	0.786342	0.79137	0.78696

4.3 增益归因分析

4.3.1 群体相对位置与最近行为的稳定贡献

S4 在 S3 的 126 维特征上增加了 58 个特征——30 个群体相对位置特征（个人值减去同职业/同学历/同性别群体的均值, 以及该差值的绝对值）和 28 个最近窗口行为特征（最近 1/3/5 笔贷款申请、最近 10/50 条分期还款和 POS 消费记录）。S4 - S3 的 OOF AUC 增益为 +0.001060, 五折中四折同向, 按稳定性判据属于稳定增益。

这一增益在量级上远小于 RQ1 中从零构建历史聚合的那一步 (+0.017), 但方向的一致性值得认真对待。机制上, 群体相对位置特征将信息从“绝对值是多少”转化为“在同类人中处于什么位置”——同一个年收入 5 万元, 对洗碗工和医生意味着完全不同的还款能力。类似地, 最近窗口特征将信息从“全量均值”转化为“最近趋势”: 一个申请人在 installments 上过去 5 年整体逾期率不高, 但最近 10 笔全部逾期——全量均值会掩盖这一恶化的信号, 而最近窗口能将其暴露出来。

值得注意的一个细节是: S4 中群体相对位置只产生差值 ($x - \bar{x}_g$) 和绝对差值 ($|x - \bar{x}_g|$), 不保留群组均值原值。这是刻意的设计——RQ1 的 S2 实验已经证明, 群组聚合原值几乎不提供增量信息; 真正有价值的是相对位置, 即“个人偏离群体均值的程度”。把原值与差值分开, 避免了把后者的功劳错记到前者头上。

4.3.2 清洗修复为何在本设定下无效

B2 相对 S4 的 OOF AUC 变化仅为 +0.000027, 五折方向混乱 (2/5 正向), 按判据属于“不稳定/证据不足”。细查发现, 这并非实现错误, 而是清洗规则与聚合列的不匹配。

复现计划规定 B2 清洗以下异常: application 沿用 S1 的五条规则 (已对所有阶段生

表 4.3: RQ2 受控配对对比。同向折数为五折中差值为正的折数。

对比	含义	Δ OOF AUC	同向折数	稳定性
S4 - S3	群体相对位置 + 最近窗口	+0.001060	4/5	稳定增益
B2 - S4	聚合前清洗修复	≈ 0	2/5	不稳定/证据不足
S5 - B2	短期/长期比值 + 趋势	+0.000146	3/5	不稳定/证据不足




图 4.1: RQ2 的 OOF AUC 增益树。只有 S4 - S3 (群体相对位置 + 最近窗口) 取得了稳定增益; 清洗修复和动态特征的贡献在本设定下无法被确认。

效)、bureau 的三个 DAYS_* 列中 < -40000 的值转为缺失、previous_application 的五个 DAYS_* 列中 $= 365243$ 的值转为缺失、credit_card 的两个 AMT_DRAWINGS_* 列中负值转为缺失。B2 代码确实正确地在聚合前应用了这些清洗。但在 S3/S4 的原始聚合中, bureau 只需要 AMT_CREDIT_SUM/DEBT/OVERDUE 和 DAYS_CREDIT; previous_application 只需要 AMT_APPLICATION/CREDIT、DAYS_DECISION 和 CNT_PAYMENT; credit_card 只需要 AMT_BALANCE、AMT_CREDIT_LIMIT_ACTUAL 和 SK_DPD。所有被清洗的列都不在聚合范围内。

因此, 虽然 B2 的每一个预测值都与 S4 不同 (预测级最大差异达 0.005, 预测相关系数 0.995), 但这些差异来自清洗对模型输入特征完全没有影响的列所导致的随机波动, 而非清洗修复带来的系统性改善。B2 - S4 本质上测量的是一个零效果——这在方法论上是一个有效的实验结果: Sunflower 的清洗修复, 其价值依赖于聚合列覆盖了清洗目标列; 在覆盖面不足时, 该修复不会产生增益。

4.3.3 动态比值与趋势缺乏稳定增益

S5 在 B2 之上增加了 7 个动态特征——4 个短期/长期比值 (POS 和 installments 的最近 10 期/50 期逾期率之比和 SK_DPD 均值之比) 和 3 个 POS CASH SK_DPD 的线性趋势 (最近 12、30、60 个月窗口)。S5 - B2 的 OOF AUC 增益为 +0.000146, 五折中仅三折同向, 按判据属于 “不稳定/证据不足”。

三个可能的原因。第一, 比值与窗口特征高度冗余: 最近 10 期和最近 50 期的聚合值已经作为独立特征 (S4 的最近窗口行为) 存在于模型中, 它们的比值在整个特征空间中被四则运算 “覆盖” 的概率很高——LightGBM 完全可以在相邻分裂中隐式地构造出分子与分母的比较。第二, SK_DPD 序列高度稀疏: POS CASH 表中 97% 的记录 $SK_DPD = 0$ 。对大多数申请人

来说, 在任何一个有限时间窗口内, SK_DPD 的序列不过是几个零和一两个非零值的混合; 对这样稀疏的信号拟合线性趋势, 斜率 $\hat{\beta}$ 的方差极大, 信息含量有限。第三, **特征数量太少**: 原方案 Sunflower 在数十个列上计算窗口比值和趋势 (而非本实验仅限定的 4 个比值 + 3 个趋势), 可能依靠大量弱信号的累积效应来获得可测量的提升。

4.4 与原始 Open Solution 历史的对照

原始 Tulip (solution-4) 宣称 CV 从 0.7840 提升到 0.7905 (+0.0065), 而 Sunflower (solution-5) 进一步提升到 0.7950 (+0.0045)。我们的受控 S4 仅取得 +0.0011, S5 几乎为零。这种差异需要仔细解释。

首先, 原始 Tulip 版本在一层中同时上线了群体相对位置、近期行为、更多清洗规则、更细粒度的历史聚合列和大量额外的手工特征, 特征数量从 solution-3 的约两百增加到 solution-4 的数百。我们的 S4 严格控制只打开两块 (群体相对位置 + 最近窗口), 特征增量被压制到 58。因此原始方案中 +0.0065 的增益中, 只有约 +0.0011 可以被归因为“相对位置与近期行为”这一特定的信息组织方式; 其余部分来自同期加入的、本实验未覆盖的更丰富的聚合与手工特征。

其次, 原始 Sunflower 版本的 +0.0045 增益, 根据本实验的 B2 和 S5 结果, **几乎不能归因于清洗修复或动态比值/趋势**——至少在我们保留的最核心的 41 个历史聚合特征上是如此。这意味着 Sunflower 的真正增益来源可能在于同期加入的 **更大规模的特征扩展** (原方案在 solution-5 中将聚合列扩展到几乎所有数值列), 而非清洗修复或动态分析本身。

4.5 本章结论

综合三组受控对比, RQ2 可以明确回答如下:

在受控复现下, Blossom $\rightarrow$ Sunflower 的后期增益中, **唯一可以确认的来源是群体相对位置和最近窗口行为** (S4 - S3 为 +0.001060, 四折同向, 稳定增益)。聚合前清洗修复在原始聚合范围下未产生增益 (B2 - S4 $\approx$ 0, 清洗目标列不在 S3/S4 的 41 个聚合特征内)。短期/长期比值和 SK_DPD 趋势特征在本实验设定下未产生稳定增益 (S5 - B2 为 +0.000146, 仅 3/5 折同向)。

将 RQ1 与 RQ2 串联起来看, 从 Chestnut 到 Sunflower 的完整证据链呈现出一个清晰的梯度:

$$+0.0105_{\text{业务比例}} > +0.0169_{\text{历史聚合}} \gg +0.0011_{\text{群体 + 最近}} \approx 0_{\text{清洗修复}} \approx 0_{\text{动态特征}}$$

最大的性能跃升来自 RQ1 阶段的多表历史聚合——把变长的行为记录转化为申请人级统计表示, 这是整个 Open Solution 演进中“信息量最大的一步”。其后 RQ2 阶段的增益虽然方向正确, 但规模已经大幅缩水 (仅为早期增益的 1/15 至 1/30)。这表明: **当核心的关系型信息已经被提取之后, 进一步精细化——包括引入群体相对位置、清洗顺序和动态变化——虽然在理论上值得追求, 但其实际收益高度依赖于特征的覆盖广度, 在最小化特征集下的独立贡献非常有限。**

Kaggle 官方 public/private 榜单结果与这一 OOF 证据链大体一致: S4、B2 和 S5 均明显高于 S3 以前的基础阶段, 但官方榜单内部排序与 OOF 排序并不完全相同。因此本文把官方分数作为外部有效性检查, 而不把它作为阶段归因的主要依据。

第五章 RQ3：在充分的特征工程之后，Stacking 能否继续提升？

5.1 本章目标

前一章已经证明，RQ2 阶段后期增益的规模远小于 RQ1 从零构建关系型表示时的跃升——群体相对位置和最近窗口仅贡献 +0.0011，而清洗修复与动态特征几乎无增益。本章面对最后一个问题：当特征工程已经充分展开之后，把不同特征版本训练出来的一级模型再做集成 (stacking)，是否还能带来进一步的提升？

原始 Open Solution 的最后一版 Four Leaf Clover 正是在多层特征工作之后，再在交叉验证中的折外 (OOF) 预测之上做 stacking——用 Logistic Regression 作为元模型，将不同特征子集或不同模型下的预测整合在一起，据称从约 0.7950 的 CV 提升到约 0.7975 (+0.0025)。这一提升看起来不大，但在竞赛后期的边际空间里被认为有价值。

本章将用受控方式重现这一 stacking 流程，并回答两个问题：

1. 简单平均（不做任何学习）能否已经超过最优单模型 S5？
2. 用 Logistic 回归学习的最优线性组合，能否提取到一级预测之间的互补信号，从而超越简单平均和 S5？

回答这两个问题的关键，在于检查不同一级模型的 OOF 预测是否犯了足够不同的错误——如果四个一级模型高度一致地给同一批人打了相近的分数，那么无论怎么组合也无法超越其中最好的那一个。

5.2 实验设计

5.2.1 一级模型与预测矩阵

S6 的输入是四个已经训练完成的一级模型的 OOF 预测：

p_{lr}^{s2} : S2 特征空间上的 L2-Logistic Regression (379 维)

p_{lgb}^{s3} : S3 特征空间上的 LightGBM (126 维, B1 + 五表历史聚合)

p_{lgb}^{s4} : S4 特征空间上的 LightGBM (184 维, S3 + 群体相对位置 + 最近窗口)

p_{lgb}^{s5} : S5 特征空间上的 LightGBM (191 维, B2 + 动态比值与趋势)

将四个 OOF 文件在 `SK_ID_CURR` 上对齐, 得到预测矩阵 $Z = [p_{lr}^{s2}, p_{lgb}^{s3}, p_{lgb}^{s4}, p_{lgb}^{s5}] \in R^{n \times 4}$, 其中 $n = 307,511$ 为训练集总申请人数。

5.2.2 简单平均

简单平均不涉及任何学习: 对每一名申请人 i , 其最终预测为:

$$\hat{p}_i^{\text{avg}} = \frac{p_{lr,i}^{s2} + p_{lgb,i}^{s3} + p_{lgb,i}^{s4} + p_{lgb,i}^{s5}}{4}.$$

该预测完全由一级模型 OOF 决定, 不需要任何额外训练, OOF AUC 可以直接从 $\hat{p}_i^{\text{avg}}$ 与标签 y_i 算得。

5.2.3 二层 CV 下的 L2-Logistic Stacking

Logistic stacking 不能直接在全局 Z 上训练并计算 OOF AUC, 否则元模型的训练目标中就包含了它自己要预测的样本, 导致乐观估计。正确做法是**二层交叉验证**:

1. 复用 `data/folds.csv` 的同一个五折划分。
2. 对每一折 k ($k = 0, 1, 2, 3, 4$): 用其余四折的 $(Z^{\text{train}}, y^{\text{train}})$ 拟合一个 L_2 -Logistic 元模型, 对该折的 Z^{valid} 做预测。
3. 五折拼接后得到完整的 stacking OOF 预测 $\hat{p}_i^{\text{stack}}$, 再计算 OOF AUC。
4. 为生成测试集预测, 在全部训练数据上拟合一个最终元模型。

元模型使用与 S2 Logistic 桥接一致的配置: `penalty=l2`、`solver=newton-cholesky`、`max_iter=1000`、`class_weight=balanced`、`random_state=2026`。输入仅限于四列一级预测, 不引入任何原始特征。

5.3 结果总览

表 5.1 给出三种方法——S5 最优单模型、简单平均、Logistic stacking——的 OOF AUC 与折间统计量, 表 5.2 给出两项对比的逐折差值与稳定性判定。

表 5.1: S5 最优单模型与两种 stacking 方法的 OOF AUC 对比。

方法	输入	OOF AUC	折 AUC 均值	折 AUC 标准差
S5 (最优单模型)	191 个特征	0.786342	0.786352	0.001491
简单平均	4 个 OOF 预测	0.777088	0.777102	0.002438
Logistic stacking	4 个 OOF 预测	0.780383	0.780414	0.002333

两项对比的 OOF AUC 差值均为负, 五折全部同向为负——不仅没有增益, 反而出现了显著的退步。Logistic stacking 虽然略好于简单平均 (差距 +0.0033), 但两者均低于 S5 单模型。

图 5.1 以增益树形式展示了 S5 到两种 stacking 方法的退化幅度。

表 5.2: S6 受控对比 (以 S5 为基线)。同向折数为五折中差值为正的折数。				
对比	含义	Δ OOF AUC	同向折数	稳定性
简单平均 - S5	四列一级预测的等权均值	-0.009254	0/5	不稳定/证据不足
Logistic stacking - S5	二层学习的最优线性组合	-0.005959	0/5	不稳定/证据不足




图 5.1: RQ3 的 OOF AUC 变化。Stacking 的两种形式均未超过最优单模型 S5; Logistic stacking 比简单平均多挽回约 0.0033, 但仍为负。

5.4 增益归因分析

5.4.1 一级预测的高度相关性

表 5.3 给出了四列一级 OOF 预测的 Pearson 相关系数矩阵。

表 5.3: 一级模型 OOF 预测的相关矩阵。				
	S2-LR	S3	S4	S5
S2-LR	1.000	0.726	0.720	0.721
S3	0.726	1.000	0.979	0.978
S4	0.720	0.979	1.000	0.991
S5	0.721	0.978	0.991	1.000

这张表直接解释了 stacking 在本实验中为何无效：

- **S3/S4/S5 三者高度相关** ($\rho = 0.978\text{--}0.991$)。它们在特征空间上虽然依次增加了群体相对位置、最近窗口和动态比值, 但输出的预测几乎相同——相关性超过 0.98。这意味着这三个 LightGBM 模型**几乎在犯相同的错误**, 它们提供了极少的互补信息。
- **S2-LR 与 LightGBM 系列适度相关** ($\rho \approx 0.72$)。Logistic 回归在相同的 379 维 S2 特征上确实捕捉到了与树模型部分不同的信号——这个相关性水平在 stacking 文献中属于“良好互补”的区间。但问题在于, S2-LR 自身的 OOF AUC 仅为 0.743, 比 S5 低了 0.043。

Stacking 的数学本质是在一级预测上拟合一个最优线性组合。假设元模型为 $\hat{p}^{\text{stack}} = \sigma(\beta_0 + \beta_1 \cdot p_{\text{lr}} + \beta_2 \cdot p_3 + \beta_3 \cdot p_4 + \beta_4 \cdot p_5)$ 。当 p_3, p_4, p_5 几乎完全共线时, $\beta_2, \beta_3, \beta_4$ 的估计方差极大, 元模型退化成一个对 p_5 (最佳单模型) 和 p_{lr} (最弱但最少冗余的模型) 的加权平衡器。而 p_{lr} 的信号质量太差, 拖低了任何包含它的加权。

5.4.2 元系数分析

为了验证上述解释, 我们在全部训练数据上拟合了最终的 Logistic 元模型。表 5.4 给出了拟合的系数。

表 5.4: Logistic stacking 元模型的系数。

输入	系数
p_{lr}^{s2} (S2-LR)	+1.716
p_{lgb}^{s3} (S3)	+1.800
p_{lgb}^{s4} (S4)	+2.290
p_{lgb}^{s5} (S5)	+3.516
截距	-1.709

元系数的排序完全符合直觉: S5 获得最高权重 (3.52), S4 次之 (2.29), S3 第三 (1.80), S2-LR 最低但并非零 (1.72)。这表明 Logistic stacking 确实在训练过程中识别出了 **S5 是最佳单模型**, 并且尝试给 S2-LR 分配一个较小的权重, 希望从它较少冗余的信号中提取些许额外信息。

然而, 即使经过这样的最优加权, stacking 的 OOF AUC 仍比 S5 本身低了 0.006。这是因为: 在一级预测高度相关的条件下, 加权组合的有效自由度远小于名义上的 4 个成分。当 p_3, p_4, p_5 之间的条件相关性如此之高时, 给它们分配不同的权重, 本质上是在拟合噪声而非信号——三个成分的加权和与 p_5 本身在排序上的差异极小。唯一能带来实质性差异的 p_{lr} , 其自身质量又不足以提升整体。

5.4.3 为什么“退步”而非持平

一个自然的疑问是: 既然 S5 是最佳单模型, 最简单的做法是给 S5 权重 1、其余权重 0——元模型为什么没有学到这一点?

答案在于**二层 CV 的严格性**和**Logistic 的线性假设**。在二层 CV 中, 元模型对每一折的训练只看到四折的数据——在任何一个训练子集上, 四个预测的相对排序和噪声结构都与全量数据略有不同。在这些子集上, S2-LR 偶尔表现出微弱的互补价值 (因为它在某些折上与 LightGBM 系列的相关性低于全量水平), 导致 Logistic 倾向于给它分配非零权重。但在全量 OOF 上评估时, 这种微弱优势不足以抵消 S2-LR 引入的噪声。

此外, Logistic 模型对输入尺度敏感——四个一级预测的取值范围和分布存在微妙差异, 使得即使元模型“知道”应该给 S5 更高权重, sigmoid 的非线性映射也会在概率空间中产生不等于 S5 直接输出的结果。

5.5 与原始 Open Solution 历史的对照

原始 Four Leaf Clover 报告了约 +0.0025 的 CV 增益 (从约 0.7950 到 0.7975), 并且被原始团队描述为“有价值的边际提升”。我们的受控 stacking 不仅没有获得正增益, 反而退步了 0.006–0.009。这一差距需要仔细解释。

原始 stacking 的输入更多样。原方案在 stacking 层使用了 Logistic Regression、神经网络、以及 在多个不同特征子集上的 LightGBM (而非我们的单一 LightGBM 系列逐层叠加)。关键是, 它在 LightGBM 系列中引入了“特征横向切分”——例如一个只用 bureau 特征的 LightGBM、一个只用 application 表特征的 LightGBM, 等等。这些横向切分的模型之间的预测相关性显著低于我们 S3→S4→S5 纵向叠加的模型, 因此互补信息更加丰富。当一级模型的 OOF 预测向量的夹角足够大时, stacking 能够做到“取长补短”; 当它们几乎共线时则不能。

原始方案的 CV 值更高, 增益空间不同。原方案在 solution-5 时 CV 已达约 0.7950, 基础比我们 S5 的 0.7863 高出约 0.009。更高的基底意味着更多的特征列、更大的特征空间和更多的模型多样性, 这些都使得 stacking 层有更丰富的信号可以利用。

我们的结果回答了本研究的核心关切。受控 stacking 实验明确告诉我们: 在特征纵向叠加的范式下, 即使把从 S2 到 S5 所有级别的模型预测都交给 stacking, 也无法从高度同质的 LightGBM 系列中提取出额外的增益。stacking 这种技术手段本身不是药方——它的价值高度依赖于一级预测之间的互补性, 而非一级预测的数量或特征的数量。

5.6 本章结论

综合以上分析, RQ3 可以明确回答如下:

在本实验的受控 stacking 中, 简单平均和 L2-Logistic stacking 均未能超越最优单模型 S5 (OOF AUC 分别为 0.777088 和 0.780383, 对比 S5 的 0.786342, 退步幅度为 -0.0093 和 -0.0060, 五折全部同向为负)。退步的原因在于: S3、S4、S5 三个 LightGBM 模型的 OOF 预测高度相关 ($\rho > 0.978$), 几乎未提供互补信息; S2-LR 虽然与 LightGBM 系列适度互补 ($\rho \approx 0.72$), 但其自身 AUC 过低 (0.743), 无法通过加权挽回整体性能。

Stacking 在有价值的特征工程完成之后, 本身不保证增益。“当特征空间的纵向扩展已经使模型饱和, 且不同模型的预测高度同质化时, stacking 层无法超越其中最好的那个一级模型。”这一结论是受控复现对 RQ3 的核心贡献——它限定了 stacking 有效的条件, 而非否定 stacking 作为技术手段的价值。

第六章 总结与结论

6.1 完整证据链

表 6.1 和图 6.1 将全部实验阶段串联成一条完整的证据链。

表 6.1: 全部受控阶段概览。 Δ 为相对父阶段的 OOF AUC 增益。

阶段	对应版本	新增内容	特征数	OOF AUC	Δ vs 父阶段
S1	Chestnut	application 基准特征	78	0.757646	–
S2	Seedling	+ 群组聚合原值	379	0.757405	–0.000241
B1	桥接	+ 业务比例 + EXT_SOURCE	85	0.768159	+0.010513
S3	Blossom	+ 五表历史聚合	126	0.785109	+0.016950
S4	Tulip	+ 群体相对位置 + 最近窗口	184	0.786169	+0.001060
B2	桥接	+ 聚合前清洗（修复无效）	184	0.786196	≈ 0
S5	Sunflower	+ 短期/长期比值 + 趋势	191	0.786342	≈ 0
S6-avg	Four Leaf Clover	简单平均 stacking	4	0.777088	–0.009254
S6-stack	Four Leaf Clover	L2-Logistic stacking	4	0.780383	–0.005959




图 6.1: 从 S1 到 S6 的完整证据链。稳定增益（黑色箭头）集中在 RQ1 的业务特征与历史聚合阶段；RQ2 的群体相对位置有微量贡献；RQ3 的 stacking 均为负效应。

6.2 对三个研究问题的最终回答

6.2.1 RQ1: 早期增益来自哪里？

回顾第三章的详细分析：

从 S1 (0.758) 到 S3 (0.785) 的 +0.027 总增益中，最大的稳定来源是多表历史聚合 ($S3 - B1 = +0.016950$ ，五折全部同向)，其次是业务比例与 EXT_SOURCE 汇总 ($B1 - S1 = +0.010513$ ，五折全部同向，单位特征效率最高)。普通 application 群组聚合原值单独没有贡献 ($S2 - S1 \approx 0$)。

6.2.2 RQ2: 后期增益来自哪里？

回顾第四章的详细分析：

从 S3 (0.785) 到 S5 (0.786) 的 +0.0012 微升中，唯一可确认的稳定来源是群体相对位置和最近窗口行为 ($S4 - S3 = +0.001060$ ，四折同向)。聚合前清洗修复在本实验的聚合列覆盖范围内无增益 ($B2 - S4 \approx 0$)。短期/长期比值与趋势特征无稳定增益 ($S5 - B2 \approx 0$)。

6.2.3 RQ3: Stacking 能否继续提升？

回顾第五章的详细分析：

在本实验条件下，简单平均和 L2-Logistic stacking 均未能超越最优单模型 S5 (简单平均 -0.009254，Logistic stacking -0.005959，五折全部同向为负)。原因是 S3/S4/S5 的 OOF 预测高度相关 ($\rho > 0.978$)，几乎不提供互补信号；S2-LR 虽适度互补但自身 AUC 过低。在特征纵向叠加的范式下，stacking 无增益。

6.3 工作假设的验证

本报告第一章提出了一个工作假设：

最大的性能增益应当来自关系型与时序型的特征表示，而不是单纯的模型选择。群组聚合可能有帮助，但预计弱于历史表特征与动态行为特征；stacking 预计只带来较小的边际增益。

现在可以逐条检验这一假设。

“最大增益来自关系型与时序型的特征表示”——成立。多表历史聚合 ($S3 - B1, +0.016950$) 和业务比例 ($B1 - S1, +0.010513$) 贡献了 RQ1 中 0.027 增量中的几乎全部。相比之下，S2 的通用群组聚合、S4 的相对位置、B2 的清洗修复和 S5 的动态特征，4 块合计增益仅约 +0.0012——关系型表示的收益占受控对比可解释增益的约 96%。

“群组聚合弱于历史表特征”——成立。普通群组聚合原值单独增益约为零。即便是群组相对位置 (S4) 的稳定增益 +0.0011，也仅为多表历史聚合的 1/15。

“stacking 只带来较小的边际增益”——更保守：不仅没有增益，反而退步。在特征纵向叠加、一级预测高度同质化的条件下，最正确的做法是不做 stacking。

整体而言，工作假设的方向是正确的，但它低估了“一级模型的特征互补性”这一前提条件的重要性。

6.4 方法论反思

本次受控复现的方法论本身就是本报告的一项重要产出。与直接横向比较历史版本分数不同，受控复现要求**固定一切非目标因素，每个阶段只改变一个特征块**，从而把“版本更新日志”转化为可验证的因果证据链。几个关键的方法论发现包括：

桥接实验的必要性。B1 和 B2 两个桥接实验是本报告中最重要设计决策。B1 把“业务比例”从“多表历史聚合”中干净地剥离，避免了把后者的功劳重复计算到前者头上；B2 揭示了原方案文档中并未标注的一个事实——Sunflower 的清洗修复在特定聚合列选择下不会产生增益。没有这些桥接，RQ1 和 RQ2 的结论将无法达到目前的清晰度。

折安全的严格执行。所有群组聚合、编码器、标准化和缺失填补都只在当前训练折上拟合，杜绝了验证折信息泄漏。这一要求使实验成本上升（需要折内循环中的特征构造），但每一组对比的可信度都建立在这一基础之上——没有它，“稳定增益”的判据就失去了意义。

“稳定增益”判据的审慎性。我们采用了“均值正 + 至少 4/5 折同向”的双重标准而非统计检验，这避免了小样本折数 $n = 5$ 下 p 值的不可靠性，同时保持了对过拟合的保守态度。实际应用中，这一判据有效地将 S2 - S1（均值接近零且方向混乱）与 S4 - S3（均值正且四折同向）区分开来，符合对实验结果的直觉判断。

受控复现的边界。受控复现天然只能回答“在我们限定的特征集下，某一机制产生了多大增益”。它不能回答“在原方案更大规模的特征集下，该机制的增益是否更大”。这也是受控复现与“原样复刻”之间的本质差异——前者追求干净的因果推断，后者追求分数的完全匹配。本文选择前者，因此每个增量都是该特征块在受控条件下的**下界估计**——当特征空间更丰富时，某些机制（尤其是 S4 和 S5）的增益可能更大，但本文不对此做出断言。

6.5 结论

本文围绕 Home Credit Open Solution 六个版本的演化历史，设计并执行了一项受控复现实验。在固定五折划分、固定 LightGBM 超参数、严格折安全的前提下，依次打开了八个特征块，将整套 Open Solution 从 0.758 到 0.786 的 OOF AUC 提升分解为可归因、可验证的配对对比。

实验结果表明：

1. **最大的性能提升来自关系型特征表示。**将五张变长历史表聚合为申请人级行为统计（bureau、previous application、installments、POS cash、credit card），贡献了 +0.016950 的稳定增益——这是整个复现链中信息增量最大的一步。
2. **业务语义特征效率极高。**仅 7 个业务比例和 EXT_SOURCE 汇总特征就贡献了 +0.010513 的稳定增益，单位特征信息密度约为多表历史聚合的 3.6 倍。
3. **后期精细化的收益远小于早期表示构造。**群体相对位置和最近窗口的稳定增益仅为 +0.001060，清洗修复与动态特征的贡献无法被确认——合计后期增益仅为早期关系型表示增益的约 1/15。

4. 在特征纵向叠加的范式下, **stacking** 不产生增益。简单平均和 Logistic stacking 均低于最优单模型 S5, 因为 LightGBM 系列 OOF 预测高度相关 ($\rho > 0.978$), 互补信号不足。

将这些发现放回竞赛语境中, 一个清晰的画面浮现出来: 从 0.74 到约 0.80 的整段旅程中, 大约 **60–70%** 可以被归因于“把关系型历史转化为申请人级统计表示”这一核心问题本身——这是一个表示学习问题, 而非模型调参问题。业务语义特征贡献了另外约 20%。剩余的约 10–15% 则被分散在群体相对位置、最近行为、清洗优化等更细颗粒度的工程优化中——这些优化在原方案更大的特征空间下可能有更显著的效果, 但在本实验的最小化受控设定下, 其独立贡献有限。

最终, 本实验以 S5 (191 维, OOF AUC 0.786342, Kaggle private 0.78696) 作为最优单模型, 完成了从 S1 到 S6 的全部受控对比。