

《工程数据分析》课程项目

—Home Credit Open Solution 的受控复现—

2026 年 6 月 21 日

1 小组分工

表 1: 小组成员与分工

姓名	主要工作
杨铮昊	实验基础设施、S1 基线、S2 群组聚合、S2-Logistic, 报告第 2 章素材
杨家骅	B1 业务特征、S3 历史聚合, 问题一分析, 报告第 3 章素材
蒙帮睿智	S4 群体相对 + 最近窗口、B2 清洗、S5 动态特征, 问题二分析, 报告第 4 章素材
杨译坤	S6 stacking、预测相关性分析, 问题三分析, 报告第 5-6 章素材, 最终报告撰写

2 问题背景与受控复现设计

2.1 问题背景

Home Credit Default Risk 竞赛要求预测贷款申请人是否会出现还款困难。每名申请人由 `SK_ID_CURR` 唯一标识, 二元标签 `TARGET` 在出现还款困难时取 1。评价指标是 ROC 曲线下面积 (AUC), 它衡量的是模型给高风险申请人赋予更高预测概率的排序能力, 而不是某个固定阈值下的分类准确率。

这份数据不是一张扁平的单表, 而是一组关系型表格。中心 `application` 表每名申请人占一行, 含基本信息、收入、资产、家庭等静态字段; 其余五张表分别记录: `bureau` (征信局历史, 含贷款金额、状态、逾期金额)、`previous_application` (历史贷款申请, 含申请金额、审批结果)、`installments_payments` (分期还款明细, 含应还/实还金额、逾期天数)、`POS_CASH_balance` (POS 与现金贷款月度余额, 含逾期状态 `SK_DPD`)、`credit_card_balance` (信用卡月度余额, 含额度、使用金额)。核心建模难点不只是“训练一个分类器”, 更在于如何把变长的历史记录转化为申请人级别的特征——这一步“表示构造”决定了模型最终能“看到”哪些信息。

开源方案 `minerva-ml/open-solution-home-credit` 经历了六个有名称的版本 (表 2): Chestnut (单表基线)、Seedling (群组聚合与多模型)、Blossom (多表历史聚合)、Tulip (群体相对与近期行为)、Sunflower (清洗修复与动态特征)、Four Leaf Clover (OOF stacking), 公开榜 AUC 从约 0.74 升至约 0.80。但这些版本不能直接当作受控实验来比较——相邻版本间特征工程、清洗规则、模型类别与超参数往往同时变化, 分数提升无法干净归因。

本项目的核心问题是当开源解答分数提升时, 究竟是哪一类新增的信息结构带来了增益? 由此引出了我们的三个研究问题 (Research Question), 分别为:

1. 问题一: 从 Chestnut 到 Blossom 的早期增益来自哪里?
2. 问题二: 从 Blossom 到 Sunflower 的后期增益来自哪里?
3. 问题三: 充分的特征工程之后, stacking 能否继续提升?

表 2: 作为项目参照的历史 Open Solution 版本。

版本	主要变化	在本项目中的角色
Chestnut	application 单表基线	S1 基线
Seedling	application 群组聚合与更多模型	S2 群组聚合
Blossom	多张历史表的聚合特征	S3 历史信息
Tulip	群体相对特征与近期行为	S4 更精细的表示
Sunflower	清洗修复与动态特征	B2/S5 清洗与动态
Four Leaf Clover	在 OOF 预测上做 stacking	S6 模型集成

2.2 实验矩阵

表 3: 受控特征阶段与对应原版本。

阶段	对应版本	特征内容	目的
S1	Chestnut	application 数值 + 类别 (78 列)	基线
S2	Seedling	S1 + 群组聚合原值 (379 列)	群组聚合
B1	桥接	S1 + 业务比例 + EXT_SOURCE 汇总 (85 列)	业务特征
S3	Blossom	B1 + 五表历史聚合 (126 列)	历史信息
S4	Tulip	S3 + 群体相对位置 + 最近窗口 (184 列)	精细表示
B2	桥接	S4, 聚合前清洗 (184 列)	清洗顺序
S5	Sunflower	B2 + 短期/长期比值 + 趋势 (191 列)	动态行为
S6	Four Leaf Clover	在一级 OOF 预测上做 stacking	预测互补

2.3 评价方法与数据安全

所有 LightGBM 阶段使用相同五折分层划分 (`data/folds.csv`, `seed=2026`)、相同 LightGBM 参数 (`lr=0.03`, `num_leaves=31`, `feature_fraction=0.20`, `reg_lambda=100`, `n_estimators=3000`, `early_stopping=100`)。主指标为折外 AUC (OOF AUC)。我们设计了一个描述性的判断标准: 平均 $\Delta > 0$ 且至少 4/5 折同向, 称为”稳定增益”; 否则为”不稳定/证据不足”。

每条 OOF 预测来自一个没见过该申请人的模型:

$$\text{OOF} = \{(\text{SK_ID_CURR}_i, y_i, \hat{p}_i, \text{fold_id}_i)\}_{i=1}^n.$$

相比训练集 AUC, OOF AUC 更可靠——每条预测都来自一个没有见过该申请人的子模型。

为了保证数据不泄漏, 我们严守一条底线: 每个群组聚合都只在当前训练折内拟合, 对验证折或测试集的申请人仅作为查找表使用。若验证折出现训练折未见过的 group, 则用训练折上该聚合的全局均值填补。构造群组聚合时绝不使用标签。任何与折相关的统计均遵循”先在训练折 fit、再分别 transform”模式——验证行永远不会参与生成用于预测自身的统计量。这一要求使实验成本上升 (需要折内循环中的特征构造), 但每一组对比的可信度都建立在这一基础之上——没有它, ”稳定增益”的判据就失去了意义。

2.4 S1/S2 详情与官方榜单

每个阶段均输出四个核心产物：`oof.parquet`（含 `SK_ID_CURR`、`TARGET`、`fold_id` 与 `prediction`）、`fold_metrics.csv`、`feature_names.txt`（特征列名，须与模型输入列完全一致）、`config.yaml`；加 `--predict-test` 时额外输出 `submission.csv`。实现校验每名训练申请人恰好出现一次、预测值有限且在 $[0, 1]$ 内、折标识与 `folds.csv` 一致。

S1 仅使用 `application` 表的 78 个特征，若干已知异常编码转为缺失（`DAYS_EMPLOYED=365243`、`CODE_GENDER=XNA` 等），刻意排除比例特征、群组聚合、历史表特征与动态窗口，作为参照点。S2 在 S1 之上加入 fold-safe 的群组聚合原值（301 个特征，379 列总计），聚合涵盖贷款金额、年金、收入、商品价格、外部评分、年龄相关天数、家庭人数与车龄等核心变量，使用 `min`、`mean`、`max`、`sum`、`var`、`median` 函数，主要分组键包括“学历 × 性别”“家庭状况 × 学历”“家庭状况 × 性别”及若干职业与地区组合。S2 只保留群组聚合原值，不构造 $x - \bar{x}_{g(i)}$ 形式的差值特征——差值保留到 S4。

为了检验 Seedling 式的特征空间是否特别依赖非线性树模型，我们在同一套 379 维 S2 特征上额外训练了一个带 L_2 正则的 Logistic 回归。数值变量在训练折内做中位数填补与标准化；类别变量做 one-hot 编码，转换时忽略未见类别。该模型不是 S2 的主结果，而是一个桥接实验，同时也是后续 S6 stacking 阶段可能的输入之一。诊断性 S2-full（含群组差值特征，801 列）OOF AUC 相对 S1 提升 +0.0027，表明信号在相对位置而非绝对统计量。

表 4 汇总所有已提交阶段的 Kaggle 官方 public/private AUC。官方榜单整体与 OOF 方向一致：B1 和 S3 在 public/private 上均明显高于 S1/S2 系列，S4/S5 均高于 S3。但 public/private 的采样噪声和排行榜划分会让相邻阶段出现轻微换序（如 S4 的 public 最高而 S5 的 private 最高）。S6 两个 stacking 版本已完成官方提交，结果同样低于 S5 单模型。因此本文把官方分数作为外部有效性检查，归因以固定 folds 下 OOF 配对对比为主。

表 4: 全阶段官方榜单汇总。

阶段	特征数	OOF AUC	Public AUC	Private AUC
S1	78	0.757646	0.74770	0.74418
S2	379	0.757405	0.74656	0.74471
S2-full	801	0.760329	0.74920	0.74859
S2-LR	379	0.743054	0.73544	0.73049
B1	85	0.768159	0.76716	0.76307
S3	126	0.785109	0.78900	0.78562
S4	184	0.786169	0.79294	0.78666
B2	184	0.786196	0.79164	0.78686
S5	191	0.786342	0.79137	0.78696
S6-avg	4	0.777088	0.77651	0.77079
S6-stack	4	0.780383	0.78104	0.77552

3 问题一：早期增益来源

3.1 对比设计与结果

问题一将早期 (Chestnut → Blossom) 拆为四组受控对比：S2–S1 (群组聚合原值)、B1–S1 (业务比例 +EXT_SOURCE)、S3–B1 (五表历史聚合)、S2-LGBM–S2-Logistic (树非线性)。

B1 是桥接实验：仅新增 7 个特征——三个业务比例 $\frac{AMT_ANNUITY}{AMT_INCOME_TOTAL}$ 、 $\frac{AMT_CREDIT}{AMT_INCOME_TOTAL}$ 、 $\frac{AMT_CREDIT}{AMT_ANNUITY}$ ，以及 EXT_SOURCE_1/2/3 的 mean、min、max、std——把”业务比例”从”多表历史”中剥离。S3 在 B1 之上接入五表历史聚合 (41 个新特征)。

表 5: 问题一各阶段结果。

阶段	模型	特征数	OOF AUC	折 AUC 标准差	同向折数
S1	LightGBM	78	0.757646	0.002460	—
S2	LightGBM	379	0.757405	0.002358	1/5
B1	LightGBM	85	0.768159	0.001864	5/5
S3	LightGBM	126	0.785109	0.001543	5/5
S2-Logistic	Logistic	379	0.743054	0.003636	—

表 6: 问题一受控配对对比。

对比	含义	Δ OOF AUC	同向折数	稳定性
S2–S1	群组聚合原值	–0.000241	1/5	不稳定
B1–S1	业务比例 +EXT_SOURCE	+0.010513	5/5	稳定
S3–B1	五表历史聚合	+0.016950	5/5	稳定
S2-LGBM–S2-Logistic	树非线性	+0.014350	5/5	稳定




图 1: 问题一 OOF AUC 增益树。

我们发现了几个有趣的规律。

群组聚合原值为何几乎无效。我们发现，S2 的 $\Delta = -0.000241$ ，五折仅 1 折正向。301 个群组均值 (如”学历 × 性别群体的收入均值”) 与底层个体变量高度共线，且对群体内所有人取相同值——LightGBM 本就能直接在底层变量上做分裂，群组均值几乎无新增信息。在 feature_fraction=0.20 的列采样下，大量低信息特征反而稀释了每棵树采到有效特征的概率。诊断性的 S2-full (加入群组差值特征) OOF AUC 提升 +0.0027，表明信号在”个体偏离群体均值的程度”而非”群体绝对统计量”——这正是把差值特征留到 S4 的原因。

业务比例的高效率。B1 仅新增 7 个特征即获得 +0.01051，单位特征增益 1.50×10^{-3} ，为问题一最高（表 7）。EXT_SOURCE 是外部征信机构已“预消化”的风险评分，其 mean/min/max 捕捉多来源共识，std 捕捉分歧——几个外部评分相互矛盾本身就是风险信号。三个业务比例把“能否负担这笔贷款”显式表达：年金/收入、贷款/收入刻画偿债压力，贷款/年金刻画还款期限结构。

多表历史聚合是最大跃升。S3-B1 的 +0.01695 是整个复现链中绝对增益最大的一步。历史表提供直接的行为证据：bureau 的在外负债规模、installments 的逾期比例刻画还款纪律、previous_application 的批准率反映被金融机构接受的程度。把变长历史记录聚合到申请人粒度是本题最关键的表示步骤——这是“把关系型历史转化为申请人级表示”这一动作的回报。

树非线性的独立贡献。S2-LGBM-S2-Logistic 的 +0.01435 衡量完全相同特征空间下模型非线性带来的价值。Logistic (OOF AUC 0.743) 甚至低于 S1 LightGBM (0.758)，说明“好特征 + 线性模型”不一定胜过“树模型 + 朴素特征”——特征表示与模型能力是两个正交维度。

表 7: 各特征块信息密度 ($\Delta\text{AUC} \div$ 新增特征数)。

特征块	新增特征数	$\Delta\text{OOF AUC}$	每特征增益
S2 群组聚合	301	-0.000241	≈ 0
B1 业务比例	7	+0.010513	$+1.50 \times 10^{-3}$
S3 历史聚合	41	+0.016950	$+4.13 \times 10^{-4}$

跨折标准差从 S1 的 0.002460 降至 B1 的 0.001864 再降至 S3 的 0.001543——有价值特征不仅抬升均值，还压低五折间波动。B1、S3 均为五折全部同向。

3.2 问题一小结

早期增益主要来自多表历史聚合 (S3-B1, +0.01695, 五折全同向)，其次为业务比例与 EXT_SOURCE (B1-S1, +0.01051)。普通群组聚合原值单独无贡献 (S2-S1 ≈ 0)。 ”多做 groupby 就会更好” 在本受控设置下不成立，群组信息真正的价值需以相对位置形式 (S4) 引入。

把上述结果放回原始版本历史，可以看到受控复现的价值。原始 Seedling 公开榜提升约 +0.005，但那是“群组聚合 + 群组差值 + 更多模型”一并上线的结果。受控 S2 单独保留群组聚合原值得增益约零——Seedling 被笼统归功于“groupby 特征”，受控对比表明真正起作用的是同期引入的相对差值与模型扩展。同时，“好特征 + 线性模型”不一定胜过“树模型 + 朴素特征”——在 379 维上 Logistic (0.743) 低于 S1 LightGBM (0.758)，说明特征表示与模型能力是两个正交维度，本报告的主线刻意固定模型、只改特征，正是为了把特征表示的贡献单独量化出来。

4 问题二：后期增益的来源

4.1 对比设计

问题二将 Blossom $\rightarrow$ Sunflower 的复合升级拆为三组独立对比：S4-S3（群体相对位置 + 最近窗口）、B2-S4（聚合前清洗修复）、S5-B2（短期/长期比值 + 趋势）。B2 是本报告最重要的桥接实验：与 S4 使用完全相同的 184 列特征，唯一区别是历史表聚

合在清洗后的原表上计算。

4.2 结果与归因

表 8: 问题二各阶段结果与配对对比。

阶段	特征数	OOF AUC	Δ vs 父阶段	同向折数
S3 (Blossom)	126	0.785109	—	—
S4 (Tulip, 群体 + 最近)	184	0.786169	+0.001060	4/5
B2 (清洗修复, 桥接)	184	0.786196	≈ 0	2/5
S5 (Sunflower, 动态特征)	191	0.786342	≈ 0	3/5




图 2: 问题二 OOF AUC 增益树。

群体相对位置与最近窗口的稳定贡献。S4 新增 58 个特征：30 个群体相对位置（个人值减去同职业/同学历/同性别群体均值及绝对差值）和 28 个最近窗口行为（最近 1/3/5 笔贷款申请、最近 10/50 条分期还款和 POS 消费记录）。 $\Delta = +0.00106$ ，四折同向，稳定但量级仅为问题一历史聚合的 1/16。机制上，“同一年收入 5 万元，对洗碗工和医生意味着完全不同的还款能力”——相对位置将信息从绝对值转化为在同类人中的位置。类似地，最近窗口特征将信息从“全量均值”转化为“最近趋势”：一个申请人在 installments 上过去 5 年整体逾期率不高，但最近 10 笔全部逾期——全量均值会掩盖这一恶化的信号，而最近窗口能将其暴露出来。S4 中群体相对位置只保留差值（ $x - \bar{x}_g$ ）和绝对差值（ $|x - \bar{x}_g|$ ），不保留群组均值原值——因为问题一已证明群组原值无增量信息，把原值与差值分开避免了把后者的功劳错记到前者头上。

清洗修复为何无效。B2-S4 的 $\Delta \approx 0$ （2/5 同向），并非实现错误，而是清洗目标列不在聚合范围内。B2 清洗 bureau 的 DAYS_* 列、previous 的 DAYS_* 列、credit_card 的 AMT_DRAWINGS_* 列——但 S3/S4 的聚合只需要 AMT_CREDIT_SUM/DEBT/OVERDUE、DAYS_CREDIT、AMT_APPLICATION/CREDIT、DAYS_DECISION、CNT_PAYMENT、AMT_BALANCE、AMT_CREDIT_LIMIT_ACTUAL、SK_DPD。所有被清洗列均不在聚合范围内。这在方法论上是有效的实验结果：Sunflower 的清洗修复，其价值依赖于聚合列覆盖清洗目标列。

动态比值与趋势无稳定增益。S5 新增 7 个特征（4 个短期/长期比值 + 3 个 POS SK_DPD 趋势）， $\Delta = +0.00015$ ，仅 3/5 折同向。原因有三：比值与窗口特征高度冗余（LightGBM 可在相邻分裂中隐式构造）；SK_DPD 序列 97% 为零，对稀疏信号拟合线性趋势斜率方差极大；本实验的特征数量远少于原方案 Sunflower（数十列窗口比值和趋势），弱信号的累积效应无法体现。此外，原方案 Sunflower 在数十个列上计算窗口比值和趋势，而非本实验仅限定的 4 个比值 + 3 个趋势——可能依靠大量弱信号的累积效应来获得可测量提升，这也是原方案 CV 值更高的一个技术解释。

4.3 与原始方案的对照

原始 Tulip 宣称 CV +0.0065，我们的受控 S4 仅 +0.0011——差额源自原方案同期加入的更丰富聚合与手工特征（特征从约 200 增至数百），我们的 S4 严格控制仅打开两块（+58 列）。原始 Sunflower 的 +0.0045 增益，根据 B2 和 S5 结果，几乎不能归因于清洗修复或动态比值/趋势——真正增益来源可能在于同期加入的大规模特征扩展（聚合列扩至几乎所有数值列），而非清洗修复或动态分析本身。

4.4 问题二小结

后期增益中唯一可确认的来源是群体相对位置和最近窗口（S4-S3，+0.0011，四折同向）。聚合前清洗在本实验的聚合列覆盖范围内无增益。短期/长期比值与趋势特征无稳定增益。后期精细化收益仅为早期关系型表示增益的约 1/15——当核心关系型信息已被提取后，进一步精细化的实际收益高度依赖特征覆盖广度。原始 Tulip 宣称的 CV +0.0065 中仅约 +0.0011 可归因于相对位置与近期行为这一特定的信息组织方式，其余来自同期加入的更丰富聚合与手工特征。原始 Sunflower 的 +0.0045 增益，根据 B2 和 S5 结果，几乎不能归因于清洗修复或动态特征——真正来源可能在于大规模特征扩展（聚合列扩至几乎所有数值列）。

$$+0.0169_{\text{历史聚合}} > +0.0105_{\text{业务比例}} \gg +0.0011_{\text{群体} + \text{最近}} \approx 0_{\text{清洗}} \approx 0_{\text{动态}}.$$

5 问题三：叠加后 Stacking 的性能评估

5.1 实验设计

S6 的输入是四个一级模型的 OOF 预测矩阵 $Z = [p_{lr}^{s2}, p_{lgb}^{s3}, p_{lgb}^{s4}, p_{lgb}^{s5}] \in \mathbb{R}^{n \times 4}$ 。文中分别采用简单平均与二层 CV 下的 L2-Logistic Stacking 两种实验策略分别进行验证，并比较实验结果。

(1) 简单平均： $\hat{p}_i^{\text{avg}} = \frac{1}{4} \sum_{j=1}^4 Z_{i,j}$ ，无需任何训练。

(2) 二层 CV 下的 L2-Logistic Stacking：复用 `folds.csv` 五折划分，对每折用其余四折的 (Z, y) 拟合 L_2 -Logistic 元模型，对该折做预测，五折拼接得到 stacking OOF。

5.2 结果与归因

表 9: S5 与两种 stacking 方法的 OOF AUC 和官方榜单。

方法	OOF AUC	Public	Private	Δ vs S5	同向折数
S5（最优单模型）	0.786342	0.79137	0.78696	—	—
简单平均	0.777088	0.77651	0.77079	-0.009254	0/5
L2-Logistic stacking	0.780383	0.78104	0.77552	-0.005959	0/5

如表 9 所示，两项对比结果表明五折全部为负，说明 stacking 不仅无增益，反而显著退步，官方 public/private 也均低于 S5。

为了解释上面现象，我们列出了四列一级 OOF 预测的相关系数矩阵，如表 10 所示。这个矩阵很好地解释了 stacking 在本实验中无效甚至起到相反效果的直接原因。根据实验结果，我们发现一级预测高度相关是退步的主要原因。S3/S4/S5 三者的相关系

表 10: 一级模型 OOF 预测相关矩阵。

	S2-LR	S3	S4	S5
S2-LR	1.000	0.726	0.720	0.721
S3	0.726	1.000	0.979	0.978
S4	0.720	0.979	1.000	0.991
S5	0.721	0.978	0.991	1.000

数 $\rho = 0.978\text{--}0.991$ ，预测相关性极高，输出预测几乎相同，说明三个 LightGBM 几乎在犯相同的错误，提供的互补信息极少。虽然 S2-LR 与 LightGBM 系列适度互补（相关系数 $\rho \approx 0.72$ ），但其自身 AUC 仅为 0.743，比 S5 低 0.043。元模型 $\hat{p} = \sigma(\beta_0 + \sum \beta_j p_j)$ 在 p_3, p_4, p_5 高度共线时， $\beta_2, \beta_3, \beta_4$ 的估计方差极大，退化成一个对 p_5 和 p_{lr} 的加权平衡器，但是由于 p_{lr} 信号质量太差，严重拖低了任何包含它的加权，因此导致实验结果呈现下降趋势。

对比两种集成策略可以看出，简单平均将四列一级预测等权混合，由于 S3/S4/S5 高度共线，其加权结果与 S5 本身差异甚微，但 S2-LR 的噪声以 25% 的权重被强制引入，导致 AUC 显著下降。Logistic Stacking 则通过数据驱动的方式学习最优权重，理论上可以压制 S2-LR 的贡献、放大 S5 的作用，因此其 AUC 优于简单平均，但是 S2-LR 的低质量信号依然对集成结果产生拖累，导致 Logistic Stacking 仍未能超越最优单模型 S5。

表 11: Logistic stacking 元模型系数。

输入	系数
p_{lr}^{s2} (S2-LR)	+1.716
p_{lgb}^{s3} (S3)	+1.800
p_{lgb}^{s4} (S4)	+2.290
p_{lgb}^{s5} (S5)	+3.516
截距	-1.709

元模型系数排序如表 11 所示，结果基本符合理论分析。S5 最高权重（3.52），S2-LR 最低（1.72）。Logistic stacking 确实识别出了 S5 是最优单模型。但二层 CV 的严格性导致在每折子集上，S2-LR 偶尔表现微弱互补价值，使元模型不忍将其权重压至零。在全集 OOF 上评估时，这种微弱优势不足以抵消 S2-LR 引入的噪声。

5.3 与原始方案的对照

原始 Four Leaf Clover 报告约 +0.0025 CV 增益（0.7950 提升到 0.7975），我们分析认为其 stacking 输入更多样——在多个不同特征子集上的 LightGBM（如一个只用 bureau、一个只用 application），即“横向切分”，不同特征预测相关性显著低于本实验 S3→S4→S5 的纵向叠加。当一级模型预测夹角足够大时，stacking 能取长补短，当它们几乎共线时则不能。此外原始方案具有更多特征列和更大的模型多样性，因此预测能力显著由于本节提出的方案。

归纳分析本节实验方案以及结果，我们发现在特征纵向叠加范式下，即使把从 S2 到 S5 所有级别的模型预测都交给 stacking 进行集成，也无法从高度同质的 LightGBM 系列中提取额外增益。因此 stacking 本身的预测水平高度依赖于一级预测之间的互补性，而非一级预测的数量或特征数。

5.4 问题三小结

综合本小结研究我们发现，简单平均和 L2-Logistic stacking 均未能超越最优单模型 S5。我们认为的退步原因在于 S3/S4/S5 高度相关 ($\rho > 0.978$)，几无互补信号，S2-LR 虽适度互补但自身 AUC 过低。因此 Stacking 不能保证预测水平一定有提升，其预测水平取决于一级预测的互补性，而不是一级预测的数量。

6 总结与反思

6.1 完整证据链

下面我们总结了全部受控阶段概览与 S1 到 S6 的完整证据链，如表 12 和图 3 所示。

表 12: 全部受控阶段概览。

阶段	新增内容	特征数	OOF AUC	Δ vs 父阶段
S1	application 基准特征	78	0.757646	—
S2	+ 群组聚合原值	379	0.757405	-0.000241
B1	+ 业务比例 +EXT_SOURCE	85	0.768159	+0.010513
S3	+ 五表历史聚合	126	0.785109	+0.016950
S4	+ 群体相对位置 + 最近窗口	184	0.786169	+0.001060
B2	+ 聚合前清洗（无效）	184	0.786196	≈ 0
S5	+ 短期/长期比值 + 趋势	191	0.786342	≈ 0
S6-avg	简单平均 stacking	4	0.777088	-0.009254
S6-stack	L2-Logistic stacking	4	0.780383	-0.005959




图 3: 从 S1 到 S6 的完整证据链。黑色箭头为稳定增益，红色箭头为负效应。

6.2 研究结论与核心发现

我们针对原方案的三个问题进行了受控复现研究，得出以下结论：

(1) 早期阶段，从 S1 (0.758) 到 S3 (0.785) 的 +0.027 中可以看出，最大稳定来源是多表历史聚合 (+0.01695)，其次是业务比例与 EXT_SOURCE (+0.01051)，普通群组聚合原值对结果几乎无贡献。

(2) 后期阶段，从 S3 (0.785) 到 S5 (0.786) 的 +0.0012 微升中可以看出，提升唯一确认的来源是群体相对位置和最近窗口 (+0.00106)。清洗修复与本实验聚合范围不匹配，因此几乎无增益。动态比值与趋势无稳定增益。

(3) 叠加 Stacking 后，简单平均和 Logistic stacking 均未能超越 S5 (退步 -0.006 至

-0.009)，因为 S3/S4/S5 预测高度相关 ($\rho > 0.978$)。在特征纵向叠加范式下，stacking 不产生增益，反而因为 S2 预测精度较低而产生负效应。

同时在研究过程中，得到了以下四点关键发现：

表 13: 本实验四项核心发现。

编号	发现	数据支撑
1	最大提升来自关系型特征表示	五表历史聚合 +0.01695，信息增量最大
2	业务语义特征效率极高	仅 7 特征 +0.01051，密度为历史聚合 3.6 倍
3	后期精细化收益远小于早期	群体 + 最近 +0.00106，清洗/动态 ≈ 0
4	Stacking 不产生增益	简单平均 -0.009，Logistic -0.006， $\rho > 0.978$

我们最终认为 S5（191 维，OOF AUC 0.786342，Kaggle private 0.78696）为最优单模型。

6.3 研究反思

我们研究采用了受控复现的方法，通过 B1 和 B2 两个桥接实验将原本耦合的多项改动逐一拆解。B1 剥离了“业务比例”与“多表历史”的混杂效应，避免后者的增益被重复归因至前者，B2 则揭示了一项原方案文档未明确的事实，即清洗修复仅在清洗列被后续聚合特征覆盖时才能产生增益，否则不构成有效干预。所有涉及折内统计量的操作均在训练折上拟合，验证折仅用于转换，不参与任何统计量的构造，从而从根本上避免了信息泄漏。

我们判断增益是否稳定，没有用 p 值，因为只有 5 折， p 值本身也不一定可靠。我们用的是更朴素的规则，平均涨了，而且 5 折里至少 4 折都朝同一个方向涨，才算稳定增益。我们报告的每一个增益，都是该特征块在受控条件下的保守估计，即便在更丰富的特征空间里某些机制的增益可能更明显，但这不是我们讨论的问题。同时，我们研究采用的受控复现不等同于原样复刻。前者要的是干净的因果推断，后者要的是分数的完全匹配。我们选了前者，所以我们报告的每一个增量，都只是在限定条件下的下限估计。