

Home Credit Open Solution 的受控复现

性能增益来自特征表示、动态行为，还是模型集成？

工业数据分析课程项目 2026 年 6 月 21 日

1 问题背景与受控复现设计

1.1 任务与动机

Home Credit Default Risk 竞赛要求预测贷款申请人是否会出现还款困难。每名申请人由 `SK_ID_CURR` 唯一标识，二元标签 `TARGET` 在出现还款困难时取 1，评价指标为 ROC 曲线下面积（AUC）——衡量模型是否给高风险申请人赋予更高预测概率的排序能力。

这份数据不是一张扁平的单表，而是一组关系型表格。中心 `application` 表每名申请人占一行，含基本信息、收入、资产、家庭等静态字段；其余五张表分别记录：`bureau`（征信局历史，含贷款金额、状态、逾期金额）、`previous_application`（历史贷款申请，含申请金额、审批结果）、`installments_payments`（分期还款明细，含应还/实还金额、逾期天数）、`POS_CASH_balance`（POS 与现金贷款月度余额，含逾期状态 `SK_DPD`）、`credit_card_balance`（信用卡月度余额，含额度、使用金额）。核心建模难点不只是“训练一个分类器”，更在于如何把变长的历史记录转化为申请人级别的特征——这一步“表示构造”决定了模型最终能“看到”哪些信息。

开源方案 `minerva-ml/open-solution-home-credit` 经历了六个有名称的版本（表 1）：`Chestnut`（单表基线）、`Seedling`（群组聚合与多模型）、`Blossom`（多表历史聚合）、`Tulip`（群体相对与近期行为）、`Sunflower`（清洗修复与动态特征）、`Four Leaf Clover`（OOF stacking），公开榜 AUC 从约 0.74 升至约 0.80。但这些版本不能直接当作受控实验来比较——相邻版本间特征工程、清洗规则、模型类别与超参数往往同时变化，分数提升无法干净归因。

表 1: 作为项目参照的历史 Open Solution 版本。

版本	主要变化	在本项目中的角色
Chestnut	<code>application</code> 单表基线	S1 基线
Seedling	<code>application</code> 群组聚合与更多模型	S2 群组聚合
Blossom	多张历史表的聚合特征	S3 历史信息
Tulip	群体相对特征与近期行为	S4 更精细的表示
Sunflower	清洗修复与动态特征	B2/S5 清洗与动态
Four Leaf Clover	在 OOF 预测上做 stacking	S6 模型集成

本项目的核心问题：当开源解答分数提升时，究竟是哪一类新增的信息结构带来了增益？三个研究问题（RQ）为：

- 1. RQ1: 从 Chestnut 到 Blossom 的早期增益来自哪里？候选：群组聚合、业务比例、多表历史。
- 2. RQ2: 从 Blossom 到 Sunflower 的后期增益来自哪里？候选：相对位置、最近窗口、

清洗修复、动态趋势。

3. RQ3: 充分的特征工程之后, stacking 能否继续提升?

1.2 实验矩阵

表 2: 受控特征阶段与对应原版本。

阶段	对应版本	特征内容	目的
S1	Chestnut	application 数值 + 类别 (78 列)	基线
S2	Seedling	S1 + 群组聚合原值 (379 列)	通用群组聚合
B1	桥接	S1 + 业务比例 + EXT_SOURCE 汇总 (85 列)	业务特征桥接
S3	Blossom	B1 + 五表历史聚合 (126 列)	历史信息
S4	Tulip	S3 + 群体相对位置 + 最近窗口 (184 列)	更精细表示
B2	桥接	S4, 聚合前清洗 (184 列)	清洗顺序
S5	Sunflower	B2 + 短期/长期比值 + 趋势 (191 列)	动态行为
S6	Four Leaf Clover	在一级 OOF 预测上做 stacking	预测互补

1.3 评价协议与折安全

所有 LightGBM 阶段使用相同五折分层划分 (`data/folds.csv`, `seed=2026`)、相同 LightGBM 参数 (`lr=0.03`, `num_leaves=31`, `feature_fraction=0.20`, `reg_lambda=100`, `n_estimators=3000`, `early_stopping=100`)。主指标为折外 AUC (OOF AUC)。增益判定采用描述性判据: 平均 $\Delta > 0$ 且至少 4/5 折同向, 称为“稳定增益”; 否则为“不稳定/证据不足”。

每条 OOF 预测来自一个没见过该申请人的模型:

$$\text{OOF} = \{(\text{SK_ID_CURR}_i, y_i, \hat{p}_i, \text{fold_id}_i)\}_{i=1}^n.$$

相比训练集 AUC, OOF AUC 更可靠——每条预测都来自一个没有见过该申请人的子模型。

折安全是核心不变量 (表 ??): 每个群组聚合都只在当前训练折内拟合, 对验证折或测试集的申请人仅作为查找表使用。若验证折出现训练折未见过的 group, 则用训练折上该聚合的全局均值填补。构造群组聚合时绝不使用标签。任何与折相关的统计均遵循“先在训练折 fit、再分别 transform”模式——验证行永远不会参与生成用于预测自身的统计量。这一要求使实验成本上升 (需要折内循环中的特征构造), 但每一组对比的可信度都建立在这一基础之上——没有它, “稳定增益”的判据就失去了意义。

1.4 可复现产物与 S1/S2 详情

每个阶段均输出四个核心产物: `oof.parquet` (含 `SK_ID_CURR`、`TARGET`、`fold_id` 与 `prediction`)、`fold_metrics.csv`、`feature_names.txt` (特征列名, 须与模型输入列完全一致)、`config.yaml`; 加 `--predict-test` 时额外输出 `submission.csv`。实现校验每名训练申请人恰好出现一次、预测值有限且在 $[0, 1]$ 内、折标识与 `folds.csv` 一致。

S1 仅使用 `application` 表的 78 个特征, 若干已知异常编码转为缺失 (`DAYS_EMPLOYED=365243`、`CODE_GENDER=XNA` 等), 刻意排除比例特征、群组聚合、历史

表特征与动态窗口，作为参照点。S2 在 S1 之上加入 fold-safe 的群组聚合原值（301 个特征，379 列总计），聚合涵盖贷款金额、年金、收入、商品价格、外部评分、年龄相关天数、家庭人数与车龄等核心变量，使用 min、mean、max、sum、var、median 函数，主要分组键包括”学历 × 性别””家庭状况 × 学历””家庭状况 × 性别”及若干职业与地区组合。S2 只保留群组聚合原值，不构造 $x - \bar{x}_{g(i)}$ 形式的差值特征——差值保留到 S4。

为了检验 Seedling 式的特征空间是否特别依赖非线性树模型，我们在同一套 379 维 S2 特征上额外训练了一个带 L_2 正则的 Logistic 回归。数值变量在训练折内做中位数填补与标准化；类别变量做 one-hot 编码，转换时忽略未见类别。该模型不是 S2 的主结果，而是一个桥接实验，同时也是后续 S6 stacking 阶段可能的输入之一。诊断性 S2-full（含群组差值特征，801 列）OOF AUC 相对 S1 提升 +0.0027，表明信号在相对位置而非绝对统计量。

表 3 汇总所有已提交阶段的 Kaggle 官方 public/private AUC。官方榜单整体与 OOF 方向一致：B1 和 S3 在 public/private 上均明显高于 S1/S2 系列，S4/S5 均高于 S3。但 public/private 的采样噪声和排行榜划分会让相邻阶段出现轻微换序（如 S4 的 public 最高而 S5 的 private 最高）。因此本文把官方分数作为外部有效性检查，归因以固定 folds 下 OOF 配对对比为主。

表 3: 全阶段官方榜单汇总。

阶段	特征数	OOF AUC	Public AUC	Private AUC
S1	78	0.757646	0.74770	0.74418
S2	379	0.757405	0.74656	0.74471
B1	85	0.768159	0.76716	0.76307
S3	126	0.785109	0.78900	0.78562
S4	184	0.786169	0.79294	0.78666
B2	184	0.786196	0.79164	0.78686
S5	191	0.786342	0.79137	0.78696

2 RQ1: 从基础特征到关系型表示

2.1 对比设计与结果

RQ1 将早期（Chestnut → Blossom）拆为四组受控对比：S2–S1（群组聚合原值）、B1–S1（业务比例 + EXT_SOURCE）、S3–B1（五表历史聚合）、S2-LGBM–S2-Logistic（树非线性）。

B1 是桥接实验：仅新增 7 个特征——三个业务比例 $\frac{\text{AMT_ANNUITY}}{\text{AMT_INCOME_TOTAL}}$ 、 $\frac{\text{AMT_CREDIT}}{\text{AMT_INCOME_TOTAL}}$ 、 $\frac{\text{AMT_CREDIT}}{\text{AMT_ANNUITY}}$ ，以及 EXT_SOURCE_1/2/3 的 mean、min、max、std——把”业务比例”从”多表历史”中剥离。S3 在 B1 之上接入五表历史聚合（41 个新特征）。

表 4: RQ1 各阶段结果。

阶段	模型	特征数	OOF AUC	折 AUC 标准差	同向折数
S1	LightGBM	78	0.757646	0.002460	—
S2	LightGBM	379	0.757405	0.002358	1/5
B1	LightGBM	85	0.768159	0.001864	5/5
S3	LightGBM	126	0.785109	0.001543	5/5
S2-Logistic	Logistic	379	0.743054	0.003636	—

表 5: RQ1 受控配对对比。

对比	含义	Δ OOF AUC	同向折数	稳定性
S2-S1	群组聚合原值	-0.000241	1/5	不稳定
B1-S1	业务比例 +EXT_SOURCE	+0.010513	5/5	稳定
S3-B1	五表历史聚合	+0.016950	5/5	稳定
S2-LGBM-S2-Logistic	树非线性	+0.014350	5/5	稳定

2.2 增益归因分析

群组聚合原值为何无效。S2 的 $\Delta = -0.000241$ ，五折仅 1 折正向。301 个群组均值（如“学历 $\times$ 性别群体的收入均值”）与底层个体变量高度共线，且对群体内所有人取相同值——LightGBM 本就能直接在底层变量上做分裂，群组均值几乎无新增信息。在 `feature_fraction=0.20` 的列采样下，大量低信息特征反而稀释了每棵树采到有效特征的概率。诊断性的 S2-full（加入群组差值特征）OOF AUC 提升 +0.0027，表明信号在“个体偏离群体均值的程度”而非“群体绝对统计量”——这正是把差值特征留到 S4 的原因。

业务比例的高效率。B1 仅新增 7 个特征即获得 +0.01051，单位特征增益 1.50×10^{-3} ，为 RQ1 最高（表 6）。EXT_SOURCE 是外部征信机构已“预消化”的风险评分，其 mean/min/max 捕捉多来源共识，std 捕捉分歧——几个外部评分相互矛盾本身就是风险信号。三个业务比例把“能否负担这笔贷款”显式表达：年金/收入、贷款/收入刻画偿债压力，贷款/年金刻画还款期限结构。

多表历史聚合是最大跃升。S3-B1 的 +0.01695 是整个复现链中绝对增益最大的一步。历史表提供直接的行为证据：bureau 的在外负债规模、installments 的逾期比例刻画还款纪律、previous_application 的批准率反映被金融机构接受的程度。把变长历史记录聚合到申请人粒度是本题最关键的表示步骤——这是“把关系型历史转化为申请入级表示”这一动作的回报。

树非线性的独立贡献。S2-LGBM-S2-Logistic 的 +0.01435 衡量完全相同特征空间下模型非线性带来的价值。Logistic（OOF AUC 0.743）甚至低于 S1 LightGBM（0.758），说明“好特征 + 线性模型”不一定胜过“树模型 + 朴素特征”——特征表示与模型能力是两个正交维度。

跨折标准差从 S1 的 0.002460 降至 B1 的 0.001864 再降至 S3 的 0.001543——有价值特征不仅抬升均值，还压低五折间波动。B1、S3 均为五折全部同向。




图 1: RQ1 OOF AUC 增益树。

表 6: 各特征块信息密度 ($\Delta\text{AUC} \div \text{新增特征数}$)。

特征块	新增特征数	$\Delta\text{OOF AUC}$	每特征增益
S2 群组聚合	301	-0.000241	≈ 0
B1 业务比例	7	+0.010513	$+1.50 \times 10^{-3}$
S3 历史聚合	41	+0.016950	$+4.13 \times 10^{-4}$

2.3 RQ1 结论与原始方案对照

早期增益主要来自多表历史聚合 (S3-B1, +0.01695, 五折全同向), 其次为业务比例与 EXT_SOURCE (B1-S1, +0.01051)。普通群组聚合原值单独无贡献 (S2-S1 ≈ 0)。 ”多做 groupby 就会更好” 在本受控设置下不成立, 群组信息真正的价值需以相对位置形式 (S4) 引入。

把上述结果放回原始版本历史, 可以看到受控复现的价值。原始 Seedling 公开榜提升约 +0.005, 但那是 ”群组聚合 + 群组差值 + 更多模型” 一并上线的结果。受控 S2 单独保留群组聚合原值得增益约零——Seedling 被笼统归功于 ”groupby 特征”, 受控对比表明真正起作用的是同期引入的相对差值与模型扩展。同时, ”好特征 + 线性模型” 不一定胜过 ”树模型 + 朴素特征”——在 379 维上 Logistic (0.743) 低于 S1 LightGBM (0.758), 说明特征表示与模型能力是两个正交维度, 本报告的主线刻意固定模型、只改特征, 正是为了把特征表示的贡献单独量化出来。

3 RQ2: 后期增益来自更精细的信息组织?

3.1 对比设计

RQ2 将 Blossom $\rightarrow$ Sunflower 的复合升级拆为三组独立对比: S4-S3 (群体相对位置 + 最近窗口)、B2-S4 (聚合前清洗修复)、S5-B2 (短期/长期比值 + 趋势)。B2 是本报告最重要的桥接实验: 与 S4 使用完全相同的 184 列特征, 唯一区别是历史表聚合在清洗后的原表上计算。

3.2 结果与归因

群体相对位置与最近窗口的稳定贡献。S4 新增 58 个特征: 30 个群体相对位置 (个人值减去同职业/同学历/同性别群体均值及绝对差值) 和 28 个最近窗口行为 (最近 1/3/5 笔贷款申请、最近 10/50 条分期还款和 POS 消费记录)。 $\Delta = +0.00106$, 四折同向, 稳定但量级仅为 RQ1 历史聚合的 1/16。机制上, ”同一年收入 5 万元, 对洗碗工

表 7: RQ2 各阶段结果与配对对比。

阶段	特征数	OOF AUC	Δ vs 父阶段	同向折数
S3 (Blossom)	126	0.785109	—	—
S4 (Tulip, 群体 + 最近)	184	0.786169	+0.001060	4/5
B2 (清洗修复, 桥接)	184	0.786196	≈ 0	2/5
S5 (Sunflower, 动态特征)	191	0.786342	≈ 0	3/5




图 2: RQ2 OOF AUC 增益树。

和医生意味着完全不同的还款能力”——相对位置将信息从绝对值转化为在同类人中的位置。类似地，最近窗口特征将信息从“全量均值”转化为“最近趋势”：一个申请人在 installments 上过去 5 年整体逾期率不高，但最近 10 笔全部逾期——全量均值会掩盖这一恶化的信号，而最近窗口能将其暴露出来。S4 中群体相对位置只保留差值 $(x - \bar{x}_g)$ 和绝对差值 $(|x - \bar{x}_g|)$ ，不保留群组均值原值——因为 RQ1 已证明群组原值无增量信息，把原值与差值分开避免了把后者的功劳错记到前者头上。

清洗修复为何无效。B2-S4 的 $\Delta \approx 0$ (2/5 同向)，并非实现错误，而是清洗目标列不在聚合范围内。B2 清洗 bureau 的 DAYS_* 列、previous 的 DAYS_* 列、credit_card 的 AMT_DRAWINGS_* 列——但 S3/S4 的聚合只需要 AMT_CREDIT_SUM/DEBT/OVERDUE、DAYS_CREDIT、AMT_APPLICATION/CREDIT、DAYS_DECISION、CNT_PAYMENT、AMT_BALANCE、AMT_CREDIT_LIMIT_ACTUAL、SK_DPD。所有被清洗列均不在聚合范围内。这在方法论上是有效的实验结果：Sunflower 的清洗修复，其价值依赖于聚合列覆盖清洗目标列。

动态比值与趋势无稳定增益。S5 新增 7 个特征（4 个短期/长期比值 + 3 个 POS SK_DPD 趋势）， $\Delta = +0.00015$ ，仅 3/5 折同向。原因有三：比值与窗口特征高度冗余（LightGBM 可在相邻分裂中隐式构造）；SK_DPD 序列 97% 为零，对稀疏信号拟合线性趋势斜率方差极大；本实验的特征数量远少于原方案 Sunflower（数十列窗口比值和趋势），弱信号的累积效应无法体现。此外，原方案 Sunflower 在数十个列上计算窗口比值和趋势，而非本实验仅限定的 4 个比值 + 3 个趋势——可能依靠大量弱信号的累积效应来获得可测量提升，这也是原方案 CV 值更高的一个技术解释。

3.3 与原始方案的对照

原始 Tulip 宣称 CV +0.0065，我们的受控 S4 仅 +0.0011——差额源自原方案同期加入的更丰富聚合与手工特征（特征从约 200 增至数百），我们的 S4 严格控制仅打开两块（+58 列）。原始 Sunflower 的 +0.0045 增益，根据 B2 和 S5 结果，几乎不能归因于清洗修复或动态比值/趋势——真正增益来源可能在于同期加入的大规模特征扩展

(聚合列扩至几乎所有数值列), 而非清洗修复或动态分析本身。

3.4 RQ2 结论

后期增益中唯一可确认的来源是群体相对位置和最近窗口 (S4-S3, +0.0011, 四折同向)。聚合前清洗在本实验的聚合列覆盖范围内无增益。短期/长期比值与趋势特征无稳定增益。后期精细化收益仅为早期关系型表示增益的约 1/15——当核心关系型信息已被提取后, 进一步精细化的实际收益高度依赖特征覆盖广度。原始 Tulip 宣称的 CV +0.0065 中仅约 +0.0011 可归因于相对位置与近期行为这一特定的信息组织方式, 其余来自同期加入的更丰富聚合与手工特征。原始 Sunflower 的 +0.0045 增益, 根据 B2 和 S5 结果, 几乎不能归因于清洗修复或动态特征——真正来源可能在于大规模特征扩展 (聚合列扩至几乎所有数值列)。

$$+0.0169_{\text{历史聚合}} > +0.0105_{\text{业务比例}} \gg +0.0011_{\text{群体} + \text{最近}} \approx 0_{\text{清洗}} \approx 0_{\text{动态}}.$$

4 RQ3: 特征纵向叠加后, Stacking 能否继续提升?

4.1 实验设计

S6 的输入是四个一级模型的 OOF 预测矩阵 $Z = [p_{lr}^{s2}, p_{lgb}^{s3}, p_{lgb}^{s4}, p_{lgb}^{s5}] \in \mathbb{R}^{n \times 4}$ ($n = 307,511$)。

简单平均: $\hat{p}_i^{\text{avg}} = \frac{1}{4} \sum_{j=1}^4 Z_{i,j}$, 无需任何训练。

二层 CV 下的 L2-Logistic Stacking: 复用 `folds.csv` 五折划分, 对每折用其余四折的 (Z, y) 拟合 L_2 -Logistic 元模型 (penalty=l2, solver=newton-cholesky, max_iter=1000, class_weight=balanced), 对该折做预测, 五折拼接得到 stacking OOF。

4.2 结果与归因

表 8: S5 与两种 stacking 方法的 OOF AUC。

方法	OOF AUC	Δ vs S5	同向折数
S5 (最优单模型)	0.786342	—	—
简单平均	0.777088	-0.009254	0/5
L2-Logistic stacking	0.780383	-0.005959	0/5

两项对比五折全部为负——stacking 不仅无增益, 反而显著退步。

表 9: 一级模型 OOF 预测相关矩阵。

	S2-LR	S3	S4	S5
S2-LR	1.000	0.726	0.720	0.721
S3	0.726	1.000	0.979	0.978
S4	0.720	0.979	1.000	0.991
S5	0.721	0.978	0.991	1.000

一级预测高度相关是退步的根本原因。S3/S4/S5 三者 $\rho = 0.978-0.991$, 输出预测

几乎相同——三个 LightGBM 几乎在犯相同的错误, 提供的互补信息极少。S2-LR 与 LightGBM 系列适度互补 ($\rho \approx 0.72$), 但其自身 AUC 仅为 0.743, 比 S5 低 0.043。元模型 $\hat{p} = \sigma(\beta_0 + \sum \beta_j p_j)$ 在 p_3, p_4, p_5 高度共线时, $\beta_2, \beta_3, \beta_4$ 的估计方差极大, 退化成一个对 p_5 和 p_{lr} 的加权平衡器——而 p_{lr} 信号质量太差, 拖低了任何包含它的加权。

表 10: Logistic stacking 元模型系数。

输入	系数
p_{lr}^{s2} (S2-LR)	+1.716
p_{lgb}^{s3} (S3)	+1.800
p_{lgb}^{s4} (S4)	+2.290
p_{lgb}^{s5} (S5)	+3.516
截距	-1.709

元系数排序符合直觉: S5 最高权重 (3.52), S2-LR 最低 (1.72)。Logistic stacking 确实识别出了 S5 是最优单模型。但二层 CV 的严格性导致在每折子集上, S2-LR 偶尔表现微弱互补价值, 使元模型不忍将其权重压至零; 在全集 OOF 上评估时, 这种微弱优势不足以抵消 S2-LR 引入的噪声。此外 sigmoid 的非线性映射和输入尺度差异也使加权组合不严格等价于直接使用 S5。

4.3 与原始方案的对照

原始 Four Leaf Clover 报告约 +0.0025 CV 增益 ($0.7950 \rightarrow 0.7975$), 其 stacking 输入更多样——在多个不同特征子集上的 LightGBM (如一个只用 bureau、一个只用 application), 即”横向切分”, 预测相关性显著低于本实验 S3→S4→S5 的纵向叠加。当一级模型预测夹角足够大时, stacking 能取长补短; 当它们几乎共线时则不能。此外原方案 CV 值更高 (0.795 vs 本实验的 0.786), 更高的基底意味着更多特征列和更大的模型多样性。

本实验的受控 stacking 明确告诉我们: 在特征纵向叠加范式下, 即使把从 S2 到 S5 所有级别的模型预测都交给 stacking, 也无法从高度同质的 LightGBM 系列中提取额外增益。stacking 本身不是药方——其价值高度依赖一级预测之间的互补性, 而非一级预测的数量或特征数。

4.4 RQ3 结论

简单平均和 L2-Logistic stacking 均未能超越最优单模型 S5 (退步 -0.006 至 -0.009, 五折全部同向为负)。退步原因: S3/S4/S5 高度相关 ($\rho > 0.978$), 几无互补信号; S2-LR 虽适度互补但自身 AUC 过低。Stacking 不保证增益——其价值取决于一级预测的互补性, 而非一级预测数量。

表 11: 全部受控阶段概览。

阶段	新增内容	特征数	OOF AUC	Δ vs 父阶段
S1	application 基准特征	78	0.757646	—
S2	+ 群组聚合原值	379	0.757405	-0.000241
B1	+ 业务比例 +EXT_SOURCE	85	0.768159	+0.010513
S3	+ 五表历史聚合	126	0.785109	+0.016950
S4	+ 群体相对位置 + 最近窗口	184	0.786169	+0.001060
B2	+ 聚合前清洗 (无效)	184	0.786196	≈ 0
S5	+ 短期/长期比值 + 趋势	191	0.786342	≈ 0
S6-avg	简单平均 stacking	4	0.777088	-0.009254
S6-stack	L2-Logistic stacking	4	0.780383	-0.005959




图 3: 从 S1 到 S6 的完整证据链。黑色箭头为稳定增益，红色箭头为负效应。

5 总结与结论

5.1 完整证据链

5.2 对三个 RQ 的最终回答

RQ1——早期增益来自哪里？从 S1 (0.758) 到 S3 (0.785) 的 +0.027 中：最大稳定来源是多表历史聚合 (+0.01695)，其次是业务比例与 EXT_SOURCE (+0.01051)；普通群组聚合原值无贡献 (≈ 0)。

RQ2——后期增益来自哪里？从 S3 (0.785) 到 S5 (0.786) 的 +0.0012 微升中：唯一确认的来源是群体相对位置和最近窗口 (+0.00106)。清洗修复与本实验聚合范围不匹配，无增益。动态比值与趋势无稳定增益。

RQ3——Stacking 能否提升？简单平均和 Logistic stacking 均未能超越 S5 (退步 -0.006 至 -0.009)，因为 S3/S4/S5 预测高度相关 ($\rho > 0.978$)。在特征纵向叠加范式下，stacking 不产生增益。

5.3 工作假设验证

“最大增益来自关系型与时序型特征表示”——成立。多表历史聚合与业务比例贡献了可解释增益的约 96%。”群组聚合弱于历史表特征”——成立。普通群组聚合原值增益为零，S4 相对位置也仅为历史聚合的 1/15。”stacking 仅带来较小边际增益”——更保守：不仅无增益，反而退步。

5.4 方法论反思

受控复现的方法论本身就是一项重要产出。桥接实验 B1 和 B2 把原本纠缠的改动拆开：B1 将“业务比例”从“多表历史”中干净剥离，避免了把后者的功劳重复计算到前者头上；B2 揭示了原方案文档未标注的事实——清洗修复在特定聚合列选择下不产生增益。折安全的严格执行使每一组对比的可信度建立在杜绝信息泄漏的基座上。”均值正 + 至少 4/5 折同向”的判据在 $n = 5$ 折下避免了 p 值不可靠的问题。受控复现天然只能回答“在限定特征集下某机制产生多大增益”，每个增量都是该特征块在受控条件下的下界估计——当特征空间更丰富时某些机制增益可能更大，但本文不对此做出断言。此外，受控复现与“原样复刻”有本质差异：前者追求干净的因果推断，后者追求分数的完全匹配。本文选择前者，因此每个增量都是该特征块在受控条件下的下界估计。

5.5 结论

本文在固定五折划分、固定 LightGBM 超参数、严格折安全的前提下，依次打开 8 个特征块，将整套 Open Solution 从 OOF AUC 0.758 到 0.786 的提升分解为可归因的配对对比。

实验结果表明：（1）最大性能提升来自关系型特征表示——将五张变长历史表聚合为申请人级行为统计，贡献了 +0.01695 的稳定增益，是整条链中信息增量最大的一步。（2）业务语义特征效率极高——仅 7 个特征即贡献 +0.01051，单位特征信息密度约为历史聚合的 3.6 倍。（3）后期精细化收益远小于早期表示构造——群体相对位置和最近窗口的稳定增益仅为 +0.00106，清洗修复与动态特征无法被确认，合计后期增益仅为早期的约 1/15。（4）在特征纵向叠加范式下，stacking 不产生增益——简单平均与 Logistic stacking 均低于最优单模型 S5，因 LightGBM 系列 OOF 预测高度相关 ($\rho > 0.978$)，互补信号不足。

从 0.74 到约 0.80 的整段旅程中，大约 60–70% 可归因于“把关系型历史转化为申请人级统计表示”这一核心问题——这是表示学习问题，而非模型调参问题。业务语义特征贡献了约 20%，剩余 10–15% 分散在群体相对位置、最近行为等更细颗粒度的工程优化中。本实验最终以 S5（191 维，OOF AUC 0.786342，Kaggle private 0.78696）为最优单模型，完成了从 S1 到 S6 的全部受控对比。

从 0.74 到约 0.80 的整段旅程中，大约 60–70% 可归因于“把关系型历史转化为申请人级统计表示”这一核心问题——这是表示学习问题，而非模型调参问题。业务语义特征贡献了约 20%，剩余 10–15% 分散在群体相对位置、最近行为等更细颗粒度的工程优化中，这些优化在原方案更大的特征空间下可能有更显著的效果，但在本实验的最小化受控设定下其独立贡献有限。本文也提醒：受控复现天然只能回答“在限定特征集下某机制产生多大增益”——每个增量都是该特征块在下界估计，当特征空间更丰富时某些机制（尤其是 S4 和 S5）的增益可能更大。